

3.2. Aktívny experiment

- ⇒ **Aktívny experiment** – zisťujú sa **odozvy** na **zámerne zavádzané vstupné** testovacie signály.
- ⇒ **Cieľ experimentu** – **vytvorenie** takých **podmienok**, aby sa dosiahli **kvalitné odhady** parametrov systému **pomocou nevelkého objemu meraní a výpočtov**.
- ⇒ **Plánovanie (navrhovanie) experimentov** (*Design of Experiments – DOE, Designed Experiments, Experimental Design*)
 - **Disciplína matematickej štatistiky**, zaoberajúca sa **štúdiom vplyvu** viacerých nezávislých premenných (faktorov) na sledovanú závislú veličinu.
 - Umožňuje **roztriediť faktory na významné a menej významné**.
 - **Vznikla v agronómii** pri systematickej analýze dielčích vplyvov na úrodu **v prvej polovici 20. storočia**. Základy modernej teórie plánovania experimentov položil sir Ronald Fischer: *The Arrangement of Field Experiments* (1926), *The Design of Experiments* (1935).
- ⇒ **Plánovaný experiment** – postupnosť **vopred naplánovaných pokusov** pri ktorých sa **cieľavedome vykonáva zmena vstupných faktorov** procesu tak, aby mohli byť **pozorované** a vhodným vyhodnotením experimentálnych dát **identifikované** odpovedajúce zmeny odozvy.

3.2.1. Ortogonálny plán pre lineárny model

- ⇒ Predpokladáme **lineárny statický n-faktorový model**

$$\hat{y} = \hat{\theta}_0 + \hat{\theta}_1' u_1' + \dots + \hat{\theta}_n' u_n'$$

kde premenné u_i' aj parametre $\hat{\theta}_i'$ majú **fyzikálny význam** a každá premenná u_i' má vymedzený **pracovný rozsah** svojimi hraničnými hodnotami

$$u_{i\min}' \leq u_i' \leq u_{i\max}'$$

Pracovná oblasť bude v priestore vstupov $\mathbf{U}' \subset \mathbb{R}^n$ mať tvar hyperkvádra s dĺžkou hrán

$$d_i = (u_{i\max}' - u_{i\min}').$$

Počet neznámych parametrov je $1 + k = 1 + n$

- ⇒ Ak pre každý z **n vstupov** uskutočníme merania na **h hladinách (hodnotách)**, potom **celkový počet bodov**, v ktorých sa budú experimenty realizovať, je $N = h^n$.
- ⇒ **Skutočné hodnoty** výstupu y sa môžu **od odhadovaných** hodnôt \hat{y} **líšiť**, čo môže byť spôsobené tým, že
 - zvolený **model** je pre aproximáciu skutočnej závislosti **nevhodný**,
 - výsledky **meraní** sú zaťažené takými **chybami**, že dochádza ku skresľovaniu hodnôt odhadovaných parametrov.

Vplyv týchto faktorov nemožno od seba oddeliť, ale **ich štatistickú separáciu** možno urobiť tak, že **v každom z N bodov urobíme q paralelných meraní** s výsledkami y_{ij} , kde $i = 1, 2, \dots, N$ a $j = 1, 2, \dots, q$ a potom v každom bode určíme výberový priemer

$$\bar{y}_i = \frac{1}{q} \sum_{j=1}^q y_{ij}$$

Rozptyl jednotlivých meraní k priemernej hodnote je mierou presnosti merania, zatiaľ čo rozptyl výstupu regresnej funkcie voči priemernej hodnote merania v každom z N bodov hovorí o adekvátnosti modelu.

⇒ **V dôsledku paralelných meraní vzrastie celkový počet meraní na $P = qN = qh^n$.** Hodnotu N možno minimalizovať tým, že **zredukujeme počet hladín na $h = 2$** (t.j. **experimenty** budeme robiť **iba v krajných hodnotách vstupných premenných** – rohových bodoch hyperkvádra), potom $N = 2^n$. V každom z týchto bodov budeme robiť **minimálne $q = 2$ merania**.

⇒ **Vstupy u'_i pretransformujeme na bezrozmerné premenné u_i**

$$u_i = \frac{u'_i - \frac{u'_{imax} + u'_{imin}}{2}}{\frac{u'_{imax} - u'_{imin}}{2}} = \frac{2u'_i - u'_{imax} - u'_{imin}}{u'_{imax} - u'_{imin}}$$

$$u_i \in \langle u'_{imin}, u'_{imax} \rangle \Rightarrow u_i \in \langle -1, 1 \rangle$$


z pôvodného hyperkvádra sa stáva **hyperkocka s dĺžkou hrany rovnou 2**. Bezrozmerné hodnoty vstupov potom nadobúdajú iba dve hodnoty: 1 pre $u'_i = u'_{imax}$ a -1 pre $u'_i = u'_{imin}$.

Potom **modelom** je rovnica: $\hat{y} = \hat{\theta}_0 + \hat{\theta}_1 u_1 + \dots + \hat{\theta}_n u_n$ a **počet meraní** je $P = q2^n$.

⇒ **Rozmiestnenie bodov merania v priestore**


dvojfaktorový lineárny plán

$$N = 2^2 = 4$$



trojfaktorový lineárny plán

$$N = 2^3 = 8$$



Matica systému H bude mať koeficienty (iba hodnoty 1 alebo -1)

$$h_{ij} = u_{ij} = (-1)^{\text{int}\left(\frac{i-1}{2^{j-1}}\right)} \quad i = 1, 2, \dots, 2^n \quad j = 0, 1, \dots, n$$

V prípade **trojfaktorového plánu** ide o problém riešenia **preurčeného systému $2^3=8$ rovníc pre $1+3=4$ neznáme regresné koeficienty**. Tabuľka ortogonálneho plánu je nasledovná:

Číslo merania	Matica H				Výstupy					
	u_0	u_1	u_2	u_3	y_1	y_2	\dots	y_q	\bar{y}	
1	1	1	1	1	x	x	\dots	x	x	
2	1	-1	1	1	x	x	\dots	x	x	
3	1	1	-1	1	x	x	\dots	x	x	
4	1	-1	-1	1	x	x	\dots	x	x	

5	1	1	1	-1	x	x	...	x	x	
6	1	-1	1	-1	x	x	...	x	x	
7	1	1	-1	-1	x	x	...	x	x	
8	1	-1	-1	-1	x	x	...	x	x	

Predposledný stĺpec obsahuje výberový priemer z q meraní.

⇒ Ak označíme jednotkový vektor dĺžky 2^n ako $\mathbf{L}_n = (1, 1, \dots, 1)^T$, potom $\mathbf{H} = (\mathbf{L}_n, \mathbf{U}_n)$, kde \mathbf{U}_n je matica rozmeru $2^n \times n$.

ORTOGONALITA

Skalárny súčin ľubovoľných dvoch stĺpcov matice \mathbf{H} je rovný nule, t.j. **stĺpce tejto matice sú navzájom ortogonálne**. Z toho vyplýva, že:

- **Súčet prvkov každého stĺpca matice \mathbf{H} je rovný 0** (okrem prvého):

$$\mathbf{L}_n^T \mathbf{u}_j = \sum_{i=1}^{2^n} u_{ij} = 0$$

- **Informačná matica \mathbf{R} aj disperzná matica \mathbf{P} sú diagonálne:**

$$\mathbf{R} = \mathbf{H}^T \mathbf{H} = \begin{pmatrix} \mathbf{L}_n^T \\ \mathbf{U}_n^T \end{pmatrix} (\mathbf{L}_n, \mathbf{U}_n) = 2^n \begin{pmatrix} 1 & \mathbf{0}^T \\ \mathbf{0} & \mathbf{I}_n \end{pmatrix} = 2^n \mathbf{I}_{n+1}$$

$$\mathbf{P} = \mathbf{R}^{-1} = \frac{1}{2^n} \mathbf{I}_{n+1}$$



V dôsledku ortogonalít plánu sa výrazne zjednodušia výpočty (nemusíme počítat inverziu matice) a tiež jednotlivé koeficienty θ_j sú navzájom nezávislé, t.j. ich kovariancia je nulová.

⇒ Zvýšením počtu faktorov o 1 dostaneme ortogonálnu maticu \mathbf{H}_{n+1} , ktorej prvým stĺpcom bude jednotkový vektor \mathbf{L}_{n+1} a zvyšných $n+1$ stĺpcov predstavuje maticu \mathbf{U}_{n+1} , ktorú získame pomocou **rekurentného vzťahu**:

$$\mathbf{U}_{n+1} = \begin{pmatrix} \mathbf{U}_n & \mathbf{L}_n \\ \mathbf{U}_n & -\mathbf{L}_n \end{pmatrix}$$

⇒ Na **výpočet jednotlivých regresných koeficientov $\hat{\theta}_j$** , $j = 0, 1, \dots, n$ použijeme Gaussov vzorec, ktorý **sa zjednoduší na tvar**:

$$\hat{\theta}_j^* = \frac{1}{2^n} \sum_{i=1}^{2^n} \bar{y}_i u_{ij} = \frac{1}{2^n} \sum_{i=1}^{2^n} \bar{y}_i (-1)^{\text{int}\left(\frac{i-1}{2^{j-1}}\right)} \quad j = 0, 1, \dots, n$$

Tieto koeficienty sú **nevychýleným odhadom** parametrov θ_j .

⇒ Pre **disperzie jednotlivých regresných koeficientov** platí:

$$\sigma_{\theta_j}^2 = \sigma^2 p_{jj} = \frac{1}{2^n} \sigma^2$$

Disperziu šumu σ^2 nepoznáme, musíme ju odhadnúť na základe nameraných údajov

$$S_{\bar{y}}^2 = \frac{Q_{\bar{y}}}{v_{\bar{y}}} \quad Q_{\bar{y}} = \sum_{i=1}^{2^n} \sum_{j=1}^q (y_{ij} - \bar{y}_i)^2 \quad v_{\bar{y}} = 2^n (q - 1)$$

$S_{\bar{y}}^2$ je **výberový rozptyl jednotlivých vzoriek (meraní) voči priemeru skupiny a odhaduje disperziu šumov σ^2** , potom pre **odhad disperzie regresných koeficientov** platí:

$$\boxed{S_{\theta_j}^2 = \frac{1}{2^n} S_{\bar{y}}^2} \quad \Rightarrow \quad \boxed{S_{\theta_j} = 2^{\frac{-n}{2}} S_{\bar{y}}}$$

⇒ Ak má **niektorý z regresných koeficientov malú hodnotu**

- jeho hodnota by **mala byť nulová**, t.j. príslušný faktor nemá vstupovať do modelu, jeho nenulová hodnota je **spôsobená chybami merania**
- jeho hodnota **má byť nenulová** a nemožno ho zanedbať.

Pri **testovaní štatistickej významnosti vplyvu jednotlivých faktorov** na výslednú regresnú závislosť môžeme použiť štatistiku t , ktorá sa riadi Studentovým rozdelením s

$$v_{\bar{y}} = 2^n(q-1) \text{ stupňami voľnosti} \quad t = \frac{\hat{\theta}_j^* - \theta_j}{S_{\theta_j}} = \frac{\hat{\theta}_j^* - \theta_j}{S_{\bar{y}}} 2^{\frac{n}{2}}$$

Dosadíme do
$$P\left(-t_{1-\frac{\alpha}{2}}(v_{\bar{y}}) \leq t \leq t_{1-\frac{\alpha}{2}}(v_{\bar{y}})\right) = 1 - \alpha$$

po úprave
$$P\left(\theta_j - t_{1-\frac{\alpha}{2}}(v_{\bar{y}}) \frac{S_{\bar{y}}}{2^{\frac{n}{2}}} \leq \hat{\theta}_j^* \leq \theta_j + t_{1-\frac{\alpha}{2}}(v_{\bar{y}}) \frac{S_{\bar{y}}}{2^{\frac{n}{2}}}\right) = 1 - \alpha$$

$$P(\theta_j - \delta \leq \hat{\theta}_j^* \leq \theta_j + \delta) = 1 - \alpha$$

Ak $\theta_j=0$, t.j. t.j. **člen $\theta_j u_j$ sa v štruktúre reálneho systému nenachádza**, potom platí

$$P(-\delta \leq \hat{\theta}_j^* \leq \delta) = 1 - \alpha$$

Koeficient $\hat{\theta}_j = 0$ a teda **faktor u_j z modelu vypustíme**, ak

$$\boxed{-\delta \leq \hat{\theta}_j^* \leq \delta} \quad \text{kde} \quad \boxed{\delta = S_{\theta_j} t_{1-\frac{\alpha}{2}}(v_{\bar{y}}) = t_{1-\frac{\alpha}{2}}(v_{\bar{y}}) \frac{S_{\bar{y}}}{2^{\frac{n}{2}}}}$$

⇒ **Adekvátnosť lineárneho modelu** (je lineárny model vhodný?)

overíme pomocou Fisher-Snedecorovho testu

$$w = \frac{S_{\tilde{y}}^2}{S_{\bar{y}}^2} = \frac{\frac{1}{2^n - n - 1} q \sum_{i=1}^{2^n} (\bar{y}_i - \hat{y}_i)^2}{\frac{1}{2^n(q-1)} \sum_{i=1}^{2^n} \sum_{j=1}^q (y_{ij} - \bar{y}_i)^2}$$

kde

$$\boxed{S_{\tilde{y}}^2 = \frac{Q_{\tilde{y}}}{v_{\tilde{y}}} \quad Q_{\tilde{y}} = q \sum_{i=1}^{2^n} (\bar{y}_i - \hat{y}_i)^2 \quad v_{\tilde{y}} = 2^n - n - 1}$$

je **výberový rozptyl výstupu regresného modelu voči priemeru skupiny údajov**.

Ak sú oba **rozptyly približne rovnaké** (t.j. **chyba modelu je približne na úrovni chyby merania**), platí $P(w \leq w_{1-\alpha}(v_{\tilde{y}}, v_{\bar{y}})) = 1 - \alpha$

Lineárny model je adekvátny, ak

$$\boxed{w \leq w_{1-\alpha}(v_{\tilde{y}}, v_{\bar{y}})}$$

v opačnom prípade je **potrebná iná štruktúra modelu**.

✓ Postup:

1. Vstupy u'_i pretransformujeme na bezrozmerné premenné $u_i \in \langle -1, 1 \rangle$

$$u_i = \frac{u'_i - \frac{u'_{\max} + u'_{\min}}{2}}{\frac{u'_{\max} - u'_{\min}}{2}} = \frac{2u'_i - u'_{\max} - u'_{\min}}{u'_{\max} - u'_{\min}} \quad i = 1, \dots, n$$

2. Vytvoríme maticu **H** – rozmiestnenie bodov merania. Zvolíme počet paralelných meraní v každom bode q . Odmeriame hodnoty výstupu y_{ij} , $i = 1, \dots, 2^n$, $j = 1, \dots, q$. Vypočítame výberový priemer z q meraní \bar{y}_i pre $i = 1, \dots, 2^n$.

3. Určíme hodnoty parametrov

$$\hat{\theta}_j = \frac{1}{2^n} \sum_{i=1}^{2^n} \bar{y}_i u_{ij} = \frac{1}{2^n} \sum_{i=1}^{2^n} \bar{y}_i (-1)^{\text{int}\left(\frac{i-1}{2^{j-1}}\right)} \quad j = 0, \dots, n$$

4. Otestujeme štatistickú významnosť parametrov. Koeficient $\hat{\theta}_j = 0$ a teda faktor u_i z modelu vypustíme, ak

$$-\delta \leq \hat{\theta}_j \leq \delta \quad \delta = S_{\bar{y}} t_{1-\frac{\alpha}{2}}(v_{\bar{y}}) = \frac{S_{\bar{y}}}{\sqrt{2^n}} t_{1-\frac{\alpha}{2}}(v_{\bar{y}})$$

$$\text{kde} \quad S_{\bar{y}}^2 = \frac{Q_{\bar{y}}}{v_{\bar{y}}} \quad v_{\bar{y}} = 2^n(q-1) \quad Q_{\bar{y}} = \sum_{i=1}^{2^n} \sum_{j=1}^q (y_{ij} - \bar{y}_i)^2$$

5. Otestujeme adekvátnosť lineárneho plánu. Lineárny model je adekvátny, ak

$$\frac{S_{\tilde{y}}^2}{S_{\bar{y}}^2} = \frac{\frac{1}{2^n - n - 1} q \sum_{i=1}^{2^n} (\bar{y}_i - \hat{y}_i)^2}{\frac{1}{2^n(q-1)} \sum_{i=1}^{2^n} \sum_{j=1}^q (y_{ij} - \bar{y}_i)^2} \leq w_{1-\alpha}(v_1, v_2) \quad \begin{aligned} v_1 &= 2^n - n - 1 \\ v_2 &= 2^n(q-1) \end{aligned}$$

$$S_{\tilde{y}}^2 = \frac{Q_{\tilde{y}}}{v_{\tilde{y}}} \quad Q_{\tilde{y}} = q \sum_{i=1}^{2^n} (\bar{y}_i - \hat{y}_i)^2 \quad v_{\tilde{y}} = 2^n - n - 1$$

📄 **Príklad** → *priklad_ortog_plan.pdf + cvičenia*

3.2.2. Ortogonálny plán pre kvadratický model

⇒ Predpokladáme **n-faktorový kvadratický model**


$$\hat{y} = \hat{\theta}_0 + \hat{\theta}_1 u_1 + \dots + \hat{\theta}_n u_n + \hat{\theta}_{n+1} u_1^2 + \dots + \hat{\theta}_{2n} u_n^2 + \hat{\theta}_{2n+1} u_1 u_2 + \dots + \hat{\theta}_k u_{n-1} u_n$$

počet neznámych parametrov

$$1 + k = \frac{1}{2} (n+1)(n+2) = 1 + \frac{1}{2} n(n+3),$$

t.j. treba **rozšíriť počet stĺpcov** matice **H** a **zväčšiť aj počet riadkov** (počet bodov plánu experimentu)

⇒ **Kompozičný plán** – kompozícia troch skupín bodov plánu:



- a) **rohové** – 2^n vrcholov hyperkocky s dĺžkou hrany rovnou dvom (pre 3-faktorový plán modré body 1-8)
- b) **osové** – $2n$ bodov na osiach, symetricky položené voči počiatku, vzdialené od neho o hodnotu α (červené body 9-14)
- c) **počiatok n-rozmerného priestoru** (zelený bod 15)
- spolu:** $N = 2^n + 2n + 1$ bodov.

⇒ Ortogonalita plánu

- nastavenie μ tak, aby súčet prvkov v stĺpcov prislúchajúcim kvadrátom faktorov bol nulový
- nastavenie α tak, aby stĺpce boli navzájom aj voči ostatným ortogonálne

$$\mu = \sqrt{\frac{2^n}{N}}$$

$$\alpha = \pm \sqrt{\frac{1}{2} \mu N (1 - \mu)}$$

Tabuľka ortogonálneho plánu pre kvadratický model:

Typy bodov	Počet bodov	Číslo polosi	Stĺpce matice H									
			u_0	Matica U			$u_1^2 - \mu$	$u_2^2 - \mu$	$u_3^2 - \mu$	$u_1 u_2$	$u_1 u_3$	$u_2 u_3$
				u_1	u_2	u_3						
			0	1	2	3	4	5	6	7	8	9
Rohové	2^n	1	1	1	1	1	$1-\mu$	$1-\mu$	$1-\mu$	1	1	1
		2	1	-1	1	1	$1-\mu$	$1-\mu$	$1-\mu$	-1	-1	1
		3	1	1	-1	1	$1-\mu$	$1-\mu$	$1-\mu$	-1	1	-1
		4	1	-1	-1	1	$1-\mu$	$1-\mu$	$1-\mu$	1	-1	-1
		5	1	1	1	-1	$1-\mu$	$1-\mu$	$1-\mu$	1	-1	-1
		6	1	-1	1	-1	$1-\mu$	$1-\mu$	$1-\mu$	-1	1	-1
		7	1	1	-1	-1	$1-\mu$	$1-\mu$	$1-\mu$	-1	-1	1
		8	1	-1	-1	-1	$1-\mu$	$1-\mu$	$1-\mu$	1	1	1
Osové	$2n$	9	1	α	0	0	$\alpha^2 - \mu$	$-\mu$	$-\mu$	0	0	0
		10	1	$-\alpha$	0	0	$\alpha^2 - \mu$	$-\mu$	$-\mu$	0	0	0
		11	1	0	α	0	$-\mu$	$\alpha^2 - \mu$	$-\mu$	0	0	0
		12	1	0	$-\alpha$	0	$-\mu$	$\alpha^2 - \mu$	$-\mu$	0	0	0
		13	1	0	0	α	$-\mu$	$-\mu$	$\alpha^2 - \mu$	0	0	0
		14	1	0	0	$-\alpha$	$-\mu$	$-\mu$	$\alpha^2 - \mu$	0	0	0
Stred	1	15	1	0	0	0	$-\mu$	$-\mu$	$-\mu$	0	0	0

⇒ Informačná matica má tvar

$$\mathbf{R} = \mathbf{H}^T \mathbf{H} = \begin{pmatrix} r_0 & \mathbf{0}^T & \mathbf{0}^T & \mathbf{0}^T \\ \mathbf{0} & r_1 \mathbf{I}_n & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & r_2 \mathbf{I}_n & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & r_3 \mathbf{I}_{\binom{n}{2}} \end{pmatrix}$$

$$\begin{aligned} r_0 &= 2^2 + 2n + 1 = N \\ r_1 &= 2^n + 2\alpha^2 = \mu N \\ r_2 &= 2^2(1-\mu)^2 + 2(\alpha^2 - \mu)^2 + (2n-1)\mu^2 = \frac{1}{2}\mu^2 N^2 (1-\mu)^2 \\ r_3 &= 2^n = \mu^2 N \end{aligned}$$

kde \mathbf{I}_n je jednotková matica rozmeru $n \times n$,

$\mathbf{I}_{\binom{n}{2}}$ je jednotková matica, ktorá má $\binom{n}{2} = \frac{1}{2}n(n-1)$ riadkov a stĺpcov

Disperzná matica

$$\mathbf{P} = \mathbf{R}^{-1}$$

→

$$p_i = \frac{1}{r_i}$$

$$\mathbf{P} = \begin{pmatrix} p_0 & \mathbf{0}^T & \mathbf{0}^T & \mathbf{0}^T \\ \mathbf{0} & p_1 \mathbf{I}_n & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & p_2 \mathbf{I}_n & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & p_3 \mathbf{I}_{\binom{n}{2}} \end{pmatrix} = \begin{pmatrix} \frac{1}{r_0} & \mathbf{0}^T & \mathbf{0}^T & \mathbf{0}^T \\ \mathbf{0} & \frac{1}{r_1} \mathbf{I}_n & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \frac{1}{r_2} \mathbf{I}_n & \mathbf{0} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \frac{1}{r_3} \mathbf{I}_{\binom{n}{2}} \end{pmatrix}$$

⇒ **Odhad hľadaných parametrov**

$$\begin{aligned} \hat{\theta}_j^* &= p_1 \sum_{i=1}^N \bar{y}_i u_{ij} & j = 1, 2, \dots, n & \text{koef. pri lineárnych členoch} \\ \hat{\theta}_j^* &= p_2 \sum_{i=1}^N \bar{y}_i (u_{i,j-n}^2 - \mu) & j = n+1, \dots, 2n & \text{koef. pri kvadratických členoch} \\ \hat{\theta}_j^* &= p_3 \sum_{i=1}^N \bar{y}_i u_{ix} u_{iz} & j = \frac{(x+1)(2n-z)}{2} + z = 2n+1, \dots, k, \quad 1 \leq x < z \leq n & \text{koef. pri zmiešaných súčinoch} \\ \hat{\theta}_0^* &= p_0 \sum_{i=1}^N \bar{y}_i - \mu \sum_{i=1}^n \hat{\theta}_{i+n}^* & & \text{absolútny člen} \end{aligned}$$

⇒ **Výberové rozptyly odhadovaných parametrov**

$$\text{cov}(\hat{\boldsymbol{\theta}}) = \sigma^2 \mathbf{P}$$

$$\begin{aligned} S_{\theta_i}^2 &= p_1 S_{\bar{y}}^2 & i = 1, 2, \dots, n & \text{koef. pri lineárnych členoch} \\ S_{\theta_i}^2 &= p_2 S_{\bar{y}}^2 & i = n+1, \dots, 2n & \text{koef. pri kvadratických členoch} \\ S_{\theta_i}^2 &= p_3 S_{\bar{y}}^2 & i = 2n+1, \dots, k & \text{koef. pri zmiešaných súčinoch} \\ S_{\theta_0}^2 &= (p_0 + \mu^2 n p_2) S_{\bar{y}}^2 & & \text{absolútny člen} \end{aligned}$$

$$\text{kde} \quad S_{\bar{y}}^2 = \frac{1}{(q-1)N} \sum_{i=1}^N \sum_{j=1}^q (y_{ij} - \bar{y}_i)^2 \quad v_{\bar{y}} = (q-1)N$$

je výberový rozptyl vzoriek voči priemeru skupiny.

⇒ **Testovanie štatistickej významnosti vplyvu jednotlivých faktorov**

Koeficient θ_j z modelu vypustíme, ak

$$-\delta_j \leq \hat{\theta}_j^* \leq \delta_j$$

kde

$$\delta_j = S_{\theta_j} t_{1-\frac{\alpha}{2}}(v_{\bar{y}})$$

⇒ **Adekvátnosť kvadratického modelu** overíme pomocou Fisher-Snedecorovho testu

$$w = \frac{S_{\bar{y}}^2}{S_y^2} = \frac{\frac{1}{N-k-1} \sum_{i=1}^N q(\bar{y}_i - \hat{y}_i)^2}{\frac{1}{N(q-1)} \sum_{i=1}^N \sum_{j=1}^q (y_{ij} - \bar{y}_i)^2}$$

$$v_1 = N - k - 1, \quad v_2 = N(q - 1)$$

Kvadratický model je adekvátny, ak

$$w \leq w_{1-\alpha}(v_1, v_2)$$

Postup:

1. Vstupy u'_i pretransformujeme na bezrozmerné premenné $u_i \in \langle -1, 1 \rangle$

$$u_i = \frac{u'_i - \frac{u'_{imax} + u'_{imin}}{2}}{\frac{u'_{imax} - u'_{imin}}{2}} = \frac{2u'_i - u'_{imax} - u'_{imin}}{u'_{imax} - u'_{imin}} \quad i = 1, \dots, n$$

2. Počet bodov je $N = 2^n + 2n + 1$ a

$$\mu = \sqrt{\frac{2^n}{N}} \quad \alpha = \pm \sqrt{\frac{1}{2} \mu N (1 - \mu)}$$

3. Vytvoríme maticu **H** – rozmiestnenie bodov merania. Zvolíme počet paralelných meraní v každom bode q . Odmeriame hodnoty výstupu y_{ij} , $i = 1, \dots, N$, $j = 1, \dots, q$. Vypočítame výberový priemer z q meraní \bar{y}_i pre $i = 1, \dots, N$.

4. Určíme prvky disperznej matice

$$p_3 = \frac{1}{\mu^2 N} \quad p_2 = \frac{2}{\mu^2 (1 - \mu)^2 N^2} \quad p_1 = \frac{1}{\mu N} \quad p_0 = \frac{1}{N}$$

5. Určíme hodnoty odhadu parametrov

$$\hat{\theta}_j^* = p_1 \sum_{i=1}^N \bar{y}_i u_{ij} \quad j = 1, 2, \dots, n \quad \text{koef. pri lineárnych členoch}$$

$$\hat{\theta}_j^* = p_2 \sum_{i=1}^N \bar{y}_i (u_{i,j-n}^2 - \mu) \quad j = n+1, \dots, 2n \quad \text{koef. pri kvadratických členoch}$$

$$\hat{\theta}_j^* = p_3 \sum_{i=1}^N \bar{y}_i u_{ix} u_{iz} \quad j = \frac{(x+1)(2n-z)}{2} + z = 2n+1, \dots, k, \quad 1 \leq x < z \leq n$$

koef. pri zmiešaných súčinoch

$$\hat{\theta}_0^* = p_0 \sum_{i=1}^N \bar{y}_i - \mu \sum_{i=1}^n \hat{\theta}_{i+n}^* \quad \text{absolútny člen}$$

6. Otestujeme štatistickú významnosť parametrov. Koeficient $\hat{\theta}_j$ z modelu vypustíme, ak

$$-\delta_j \leq \hat{\theta}_j \leq \delta_j \quad \delta_j = S_{\theta_j} t_{1-\frac{\alpha}{2}}(v_{\bar{y}})$$

$$S_{\theta_i}^2 = p_1 S_{\bar{y}}^2 \quad i = 1, 2, \dots, n \quad \text{koef. pri lineárnych členoch}$$

$$S_{\theta_i}^2 = p_2 S_{\bar{y}}^2 \quad i = n+1, \dots, 2n \quad \text{koef. pri kvadratických členoch}$$

$$S_{\theta_i}^2 = p_3 S_{\bar{y}}^2 \quad i = 2n+1, \dots, k \quad \text{koef. pri zmiešaných súčinoch}$$

$$S_{\theta_0}^2 = (p_0 + \mu^2 n p_2) S_{\bar{y}}^2 \quad \text{absolútny člen}$$

$$Q_{\bar{y}} = \sum_{i=1}^N \sum_{j=1}^q (y_{ij} - \bar{y}_i)^2 \quad v_{\bar{y}} = N(q-1) \quad S_{\bar{y}}^2 = \frac{Q_{\bar{y}}}{v_{\bar{y}}}$$

7. Otestujeme adekvátnosť kvadratického plánu. Kvadratický model je adekvátny, ak

$$\frac{S_{\bar{y}}^2}{S_{\bar{y}}^2} = \frac{\frac{1}{N-k-1} \sum_{i=1}^N q(\bar{y}_i - \hat{y}_i)^2}{\frac{1}{N(q-1)} \sum_{i=1}^N \sum_{j=1}^q (y_{ij} - \bar{y}_i)^2} \leq w_{1-\alpha}(v_1, v_2) \quad v_1 = N-k-1, \quad v_2 = N(q-1)$$