

4 MODELY LINEÁRNYCH DYNAMICKÝCH SYSTÉMOV

4.1. Deterministické modely

⇒ Výstup zo systému je závislý iba od vstupných veličín a od času a neuvažuje sa vplyv náhodných porúch.

4.1.1. Parametrické modely

⇒ Vzťah medzi nezávislou a závislou premennou / premennými je **vyjadrený analyticky ako funkcia nezávislej premennej a konečného počtu parametrov s danou štruktúrou**.

1. *Lineárna diferenciálna rovnica (spojitý model)*


$$a_n \frac{d^n y(t)}{dt^n} + a_{n-1} \frac{d^{n-1} y(t)}{dt^{n-1}} + \dots + y(t) = b_m \frac{d^m u(t)}{dt^m} + \dots + b_0 u(t)$$

alebo

$$A(s)y(s) = B(s)u(s)$$

$$A(s) = 1 + a_1 s + \dots + a_{n-1} s^{n-1} + a_n s^n$$

$$B(s) = b_0 + b_1 s + \dots + b_{m-1} s^{m-1} + b_m s^m$$



alebo s dopravným oneskorením $A(s)y(s) = e^{-T_d s} B(s)u(s)$

2. *Lineárna diferenčná rovnica (diskrétny model)*


$$y(k) = -a_1 y(k-1) - \dots - a_n y(k-n) + b_1 u(k-d-1) + \dots + b_m u(k-d-m)$$

alebo

$$A(q^{-1})y(k) = B(q^{-1})u(k-d)$$

$$A(z^{-1}) = 1 + a_1 z^{-1} + \dots + a_{n-1} z^{-n+1} + a_n z^{-n}$$

$$B(z^{-1}) = b_1 z^{-1} + \dots + b_{m-1} z^{-m+1} + b_m z^{-m}$$



⇒ Cieľom identifikácie je odhadnúť:

?

- koeficienty polynómov A a B pre dané rády n a m
- prípadne aj rády n a m
- dopravné oneskorenie T_d alebo d.

⇒ Typické štruktúry modelov používané v **spojitých technológiách**:

Prvý rád s dopravným oneskorením:

$$\frac{Ke^{-Ds}}{Ts + 1}$$

Druhý rád s dopravným oneskorením:

$$\frac{Ke^{-Ds}}{(T_1 s + 1)(T_2 s + 1)}$$

Jedna nula, dva póly s dopravným oneskorením:

$$\frac{K(T_3 s + 1)e^{-Ds}}{(T_1 s + 1)(T_2 s + 1)}$$

4.1.2. Neparametrické modely

⇒ Vzťah medzi nezávislou a závislou premennou / premennými je **vyjadrený v grafickej alebo tabelárnej forme, nevyžadujú žiadnu informáciu o štruktúre modelu, parametre nie sú v modeli explicitne prítomné.**

1. *Impulzná funkcia*

⇒ **Impulzná funkcia** (resp. **váhová funkcia**) $h(t)$ je **odozva systému na vstupný signál v tvare Diracovho (jednotkového) impulzu $\delta(t)$** , pre ktorý platí

$$\delta(t) = \begin{cases} \infty & t = 0 \\ 0 & t \neq 0 \end{cases} \quad \text{a} \quad \int_{-\infty}^{\infty} \delta(t) dt = 1$$

⇒ **Grafická podoba** impulznej funkcie sa **nazýva prechodová charakteristika.**

⇒ **Výstupný signál** lineárneho systému pre **ľubovoľný deterministický vstupný signál** sa dá určiť pomocou **konvolutórneho integrálu**

$$y(t) = \int_0^t h(t-\tau)u(\tau)d\tau \quad \text{resp.} \quad y(t) = \int_0^t h(\tau)u(t-\tau)d\tau$$

⇒ **FIR (Finite Impulse Response) model (diskrétny prípad)**

Ak je na **vstupe** systému postupnosť signálov v tvare:

$$\{u(0), u(1), u(2), \dots, u(k), \dots\} = \{1, 0, 0, \dots, 0, \dots\}$$

potom **odozva výstupu** systému je

$$\{y(0), y(1), y(2), \dots, y(k), \dots\} = \{h_0, h_1, h_2, \dots, h_k, \dots\}$$


pričom platí:

- $h_0 = 0$, t.j. **výstup nereaguje okamžite na vstup**,
- $h_k = 0$ pre $k > n$, t.j. **po n krokoch odozva systému na impulz odznie** (systém musí byť stabilný), kde n je **horizont modelu**.

Odozvu systému na ľubovoľnú postupnosť vstupných signálov je možné získať pomocou **konvolutórnej sumy**

$$y(t) = \sum_{i=1}^n h_i u(t-i)\Delta\tau = H(z^{-1})u(t)$$

t.j. na jej výpočet je potrebné zapamätať posledných n hodnôt vstupného signálu.



⇒ V prípade, že pri **meraní impulznej odzvy** je použitý impulz s veľkosťou $\alpha \neq 1$, odozva výstupu bude

$$y(t) = \alpha h(t)$$

a **odhad impulznej funkcie** bude

$$\hat{h}(t) = \frac{y(t)}{\alpha}$$

Pri meraní sa **odporúča použiť impulz s maximálnou možnou veľkosťou** z dôvodu redukcie vplyvu šumu merania.

2. Prechodová funkcia

⇒ **Prechodová funkcia $g(t)$** je odozva systému na **vstupný signál v tvare jednotkového skoku $\eta(t)$** , pre ktorý platí

$$\eta(t) = \begin{cases} 0 & t < 0 \\ 1 & t \geq 0 \end{cases}$$

⇒ **Grafická podoba** prechodovej funkcie sa **nazýva prechodová charakteristika**.

⇒ Pre prechodovú funkciu platí

$$g(t) = \int_0^t h(\tau) d\tau$$

potom **impulzná funkcia je časová derivácia prechodovej funkcie**

$$h(t) = \frac{dg(t)}{dt}$$

⇒ **SR (Step Response) model (diskrétny prípad)**

Pre **jednotkový vstupný signál**:

$$\{u(0), u(1), u(2), \dots, u(k), \dots\} = \{1, 1, 1, \dots, 1, \dots\}$$

nadobudne **výstup systému** tvar:

$$\{y(0), y(1), y(2), y(3), \dots\} = \{h_0, h_1, h_1 + h_2, h_1 + h_2 + h_3, \dots\} = \{0, g_1, g_2, g_3, \dots\}$$

kde g_i , $i = 1, 2, \dots$ sú **koefficienty prechodovej charakteristiky** systému spĺňajúce predpoklady:

- $g_0 = 0$, t.j. výstup nereaguje okamžite na skokový signál,
- $g_{n+1} = g_{n+2} = \dots = g_\infty$, t.j. po n krokoch sa výstup systému ustáli.

⇒ **Koefficienty prechodovej charakteristiky** je možné **priamo vypočítať z koefficientov impulznej charakteristiky** a naopak:


$$g_k = \Delta\tau \sum_{i=1}^k h_i$$

$$h_k = \frac{g_k - g_{k-1}}{\Delta\tau}$$

⇒ **Odozvu systému na ľubovoľnú postupnosť vstupných signálov** je možné získať pomocou vzťahu

$$y(t) = \sum_{i=1}^n g_i \Delta u(t-i) = G(z^{-1})(1-z^{-1})u(t)$$

kde $\Delta u(i) = u(i) - u(i-1)$.



⇒ V prípade, že pri **meraní prechodovej charakteristiky** je použitý skok s veľkosťou $\alpha \neq 1$, odhad prechodovej charakteristiky je

$$\hat{g}(t) = \frac{y(t)}{\alpha}$$

Poznámka:

Neparametrické modely sa **využívajú** najmä pri **syntéze prediktívneho riadenia**.

Príklady → **priklady_neparam_mod.pdf**

4.2. Stochastické modely


- ⇒ Na **výstup pôsobia stochastické poruchy a šumy merania** popísané postupnosťami náhodných premenných.
- ⇒ Podľa toho, **akým spôsobom sa prejavuje porucha na výstupe**, môžu byť definované rôzne štruktúry modelov.
- ⇒ **Poruchový signál** môže byť v tvare náhodného procesu
 - biely šum $\xi(t)$
 - farebný šum $v(t)$ = filtrovaný biely šum.

4.2.1. Modely náhodných procesov

ARMA (AutoRegressive Moving Average) proces

stacionárny náhodný proces $v(k)$ reprezentovaný ako **biely šum $\xi(k)$ filtrovaný cez lineárny filter**

$$v(k) = \frac{C(z^{-1})}{D(z^{-1})} \xi(k)$$



kde $C(z^{-1}) = 1 + c_1 z^{-1} + \dots + c_{nc} z^{-nc}$


$$D(z^{-1}) = 1 + d_1 z^{-1} + \dots + d_{nd} z^{-nd}$$

potom $v(k) = -d_1 v(k-1) - \dots - d_{nd} v(k-nd) + \xi(k) + c_1 \xi(k-1) + \dots + c_{nc} \xi(k-nc)$


$$D(z^{-1})v(k) = C(z^{-1})\xi(k)$$

ARMA proces môže byť rozdelený na dve časti:

- **AR (AutoRegressive)** keď $nc = 0$
(autoregresívny, odhad $v(k)$ na základe minulých hodnôt $v(k-i)$ a okamžitej hodnoty $\xi(k)$)
 $v(k) = -d_1 v(k-1) - \dots - d_{nd} v(k-nd) + \xi(k)$
 $D(z^{-1})v(k) = \xi(k)$



- **MA (Moving Average)** keď $nd = 0$
(váhovaný priebežný priemer hodnôt bieleho šumu)
 $v(k) = \xi(k) + c_1 \xi(k-1) + \dots + c_{nc} \xi(k-nc)$
 $v(k) = C(z^{-1})\xi(k)$



4.2.2. Modely dynamických systémov

1. ARX (AutoRegressive with eXogenous input) model


- ⇒ **Náhodný proces v podobe bieleho šumu** vstupuje priamo do rovnice procesu ako **extra vstup**.
- ⇒ Patrí medzi najčastejšie používané modely pri identifikácii.
- ⇒ V špeciálnom prípade, keď $na = 0$ prejde na FIR (Finite Impulse Response) model.

$$A(z^{-1})y(k) = B(z^{-1})u(k) + \xi(k)$$

$$B(z^{-1}) = b_1 z^{-1} + \dots + b_{nb} z^{-nb}$$

$$A(z^{-1}) = 1 + a_1 z^{-1} + \dots + a_{na} z^{-na}$$

$$y(k) = -a_1 y(k-1) - \dots - a_{na} y(k-na) + b_1 u(k-1) + \dots + b_{nb} u(k-nb) + \xi(k)$$




2. ARMAX (AutoRegressive Moving Average with eXogenous input) model alebo CARMA (Controlled AutoRegressive Moving Average) model

⇒ Náhodný proces vstupuje do systému ako MA proces

$$A(z^{-1})y(k) = B(z^{-1})u(k) + C(z^{-1})\xi(k)$$


$$y(k) = -a_1 y(k-1) - \dots - a_{na} y(k-na) + b_1 u(k-1) + \dots + b_{nb} u(k-nb) + \xi(k) + c_1 \xi(k-1) + \dots + c_{nc} \xi(k-nc)$$



3. ARARX (AutoRegressive AutoRegressive with eXogenous input) model

⇒ Náhodný proces vstupuje do systému ako AR proces

$$A(z^{-1})y(k) = B(z^{-1})u(k) + \frac{1}{D(z^{-1})}\xi(k)$$



4. ARIX (AutoRegressive Integrated with eXogenous input) model

⇒ Predpokladá nestacionárnu poruchu v podobe bieleho šumu filtrovaného cez integrátor (špeciálny prípad ARARX modelu)

$$A(z^{-1})y(k) = B(z^{-1})u(k) + \frac{1}{D(z^{-1})}\xi(k)$$

kde $D(z^{-1}) = 1 - z^{-1}$ zodpovedá diskrétnemu integrátoru.


5. ARIMAX (AutoRegressive Integrated Moving Average with eXogenous input) model

alebo CARIMA (Controlled AutoRegressive Integrated Moving Average) model

⇒ Predpokladá nestacionárnu poruchu v podobe MA procesu filtrovaného cez integrátor

$$A(z^{-1})y(k) = B(z^{-1})u(k) + \frac{C(z^{-1})}{D(z^{-1})}\xi(k)$$

$$D(z^{-1}) = 1 - z^{-1}$$



6. OEM (Output Error Model) model

⇒ **K** výstupnej premennej je pridaný biely šum
(chyba merania)


$$y(k) = \frac{B(z^{-1})}{F(z^{-1})} u(k) + \xi(k)$$

$$F(z^{-1}) = 1 + f_1 z^{-1} + \dots + f_{nf} z^{-nf}$$

$$y(k) = x(k) + \xi(k)$$

$$x(k) = -f_1 x(k-1) - \dots - f_{nf} x(k-nf) + b_1 u(k-1) + \dots + b_{nb} u(k-nb)$$

$x(k)$ – neskreslený výstup




7. Box-Jenkinsov (BJ) model

⇒ **K** výstupnej premennej je pridaný farebný šum

$$y(k) = \frac{B(z^{-1})}{F(z^{-1})} u(k) + \frac{C(z^{-1})}{D(z^{-1})} \xi(k)$$

$$F(z^{-1})D(z^{-1})y(k) - B(z^{-1})D(z^{-1})u(k) = C(z^{-1})F(z^{-1})\xi(k)$$



BJ model je možné previesť na ARMAX model, ak označíme

$$\tilde{A}(z^{-1}) = F(z^{-1})D(z^{-1})$$


$$\tilde{B}(z^{-1}) = B(z^{-1})D(z^{-1})$$

$$\tilde{C}(z^{-1}) = C(z^{-1})F(z^{-1})$$

8. Åströmov model

⇒ Najvšeobecnejšia štruktúra

$$A(z^{-1})y(k) = \frac{B(z^{-1})}{F(z^{-1})} u(k) + \frac{C(z^{-1})}{D(z^{-1})} \xi(k)$$



Predchádzajúce modely dostaneme ako **špeciálne prípady** tohto modelu:

- ARX: $n_c = n_d = n_f = 0$
- ARMA: $n_b = n_d = n_f = 0$
- ARMAX: $n_d = n_f = 0$
- ARARX: $n_c = n_f = 0$
- ARIMAX: $n_f = 0$
- OE: $n_c = n_d = n_a = 0$
- BJ: $n_a = 0$

9. Systémy s dopravným oneskorením

Ak je hodnota dopravného oneskorenia n_k

$$B(z^{-1}) = z^{-n_k}(b_1 z^{-1} + \dots + b_{n_b} z^{-n_b})$$

10. Stavový model

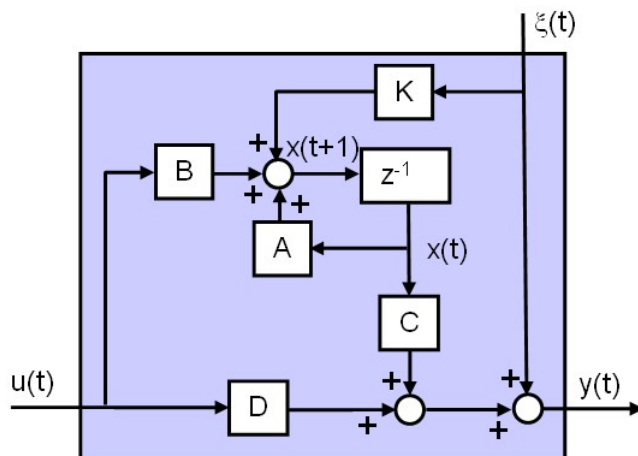
⇒ Popisuje **rovnaký** lineárny **vzťah medzi vstupom a výstupom ako ARX model**, ale používa iba oneskorenie o jeden krok (periódu vzorkovania), na tento účel využíva stavové premenné

⇒ Rád stavového modelu súvisí s počtom minulých (oneskorených) vstupov a výstupov v lineárnej diferenciálnej rovnici

⇒ Užitočný najmä v prípade systémov s viacerými výstupmi

$$\begin{cases} x(t+1) = Ax(t) + Bu(t) + K\xi(t) \\ y(t) = Cx(t) + Du(t) + \xi(t) \end{cases}$$

⇒ Ak $K=0$, šum ovplyvňuje priamo výstup → ekvivaletné OE modelu



Poznámka:

MATLAB System Identification Toolbox - funkcie

arx	Estimate parameters of ARX or AR model using least squares
armax	Estimate parameters of ARMAX model using time-domain data
bj	Estimate Box-Jenkins polynomial model using time domain data
iv4	ARX model estimation using four-stage instrumental variable method
ivx	ARX model estimation using instrumental variable method with arbitrary instruments
oe	Estimate Output-Error polynomial model using time or frequency domain data