

3.3. Pasívny experiment

⇒ **Pasívny experiment** – využitie veličín z prevádzkových podmienok, **nemáme možnosť ovplyvniť voľbu bodov merania**

⇒ Predpokladáme náhradu funkčnej závislosti $y = F(\mathbf{u}, \boldsymbol{\theta}) + v$

regresnou funkciou $\hat{y} = \hat{\boldsymbol{\theta}}^T \mathbf{f}(\mathbf{u})$

$$\hat{\boldsymbol{\theta}} = (\hat{\theta}_0, \hat{\theta}_1, \dots, \hat{\theta}_n)^T \quad k = n + 1 \text{ neznámych parametrov}$$

$$\mathbf{f}(\mathbf{u}) = (f_0(\mathbf{u}), f_1(\mathbf{u}), \dots, f_n(\mathbf{u}))^T$$

Predpokladajme, že uskutočníme celkom $N \gg 1 + n$ meraní, potom optimálny odhad dostaneme pomocou **Gaussovho vzťahu**

$$\boxed{\hat{\boldsymbol{\theta}}^* = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}}$$

👉 **Negatíva:**

- Matica **H** bude v týchto prípadoch **plnou maticou** a matice **P** a **R** teda **nebudú diagonálne**.
- Súčasťou riešenia **nebude hodnota účelovej funkcie**.
- Aj keď sa zdá, že je riešenie Gaussovho vzťahu aj v prípade pasívneho experimentu jednoduché, predsa môžu vzniknúť problémy v prípadoch, keď:
 - 1) matica **R** je **singulárna** ($\det(\mathbf{R})=0$, t.j. **neinvertovateľná**)
 - 2) matica **R** je **zle podmienená** ($\det(\mathbf{R})$ je malé číslo, $\mathbf{R} \mathbf{R}^{-1} \neq \mathbf{R}^{-1} \mathbf{R} \neq \mathbf{I}$)
 - 3) zvolíme nevhodné postupy pre určenie matice $\mathbf{P} = \mathbf{R}^{-1}$, resp. **nevhodný postup riešenia systému rovníc**
 - 4) **obmedzená presnosť počítača a zaokrúhľovanie** pri zostavovaní matice **R**.

⇒ Cieľom je modifikovať riešenie tak, aby sme sa vyhli výpočtu matice **P** (inverzii **R**).

3.3.1. Jednorazové metódy

⇒ **Dávkové – jednorazové spracovanie údajov**

⇒ **Možnosti riešenia napr.:**

- **priame riešenie normálnych rovníc** $\mathbf{H}^T \mathbf{H} \hat{\boldsymbol{\theta}}^* = \mathbf{H}^T \mathbf{y}$
- **riešenie preurčeného systému rovníc** $\mathbf{y} = \mathbf{H} \hat{\boldsymbol{\theta}}^*$
 - **singulárny rozklad matice H** (SVD – Singular Value Decomposition)
 - **QR rozklad matice H**.

⇒ **QR rozklad matice H**

Ortogonalný alebo QR rozklad reprezentuje maticu ako súčin ortogonálnej matice **Q** a hornej trojuholníkovej matice **R**.

$$\mathbf{H} = \mathbf{Q} \mathbf{R}$$

Ortogonalná matica Q je štvorcová matica, pre ktorú platí: $\mathbf{Q}^T = \mathbf{Q}^{-1} \Rightarrow \mathbf{Q}^T \mathbf{Q} = \mathbf{I}$.

Potom **preurčený systém rovníc**

$$\mathbf{y} = \mathbf{H} \hat{\boldsymbol{\theta}}^*$$

môžeme **pretransformovať**

$$\mathbf{Q}^T \mathbf{y} = \mathbf{Q}^T \mathbf{H} \hat{\boldsymbol{\theta}}^* = \mathbf{Q}^T \mathbf{Q} \mathbf{R} \hat{\boldsymbol{\theta}}^* = \mathbf{R} \hat{\boldsymbol{\theta}}^*$$

Riešenie systému rovníc

$$\mathbf{Q}^T \mathbf{y} = \mathbf{R} \hat{\boldsymbol{\theta}}^*$$

je jednoduché, keďže \mathbf{R} je horná trojuholníková matica.

 **Príklad** → *priklad_preurc_syst.pdf*

Negatíva jednorazových metód

- v prípade **nového experimentu** (v preurčenom systéme rovníc sa pridá ďalší $N + 1$ riadok) je potrebné **opakovať všetky výpočty v plnom rozsahu**
- pri väčšom počte údajov **veľké nároky na pamäť** a realizácia výpočtov môže byť **mimo reálneho času**.

3.3.2. Rekurzívne metódy

⇒ **Nové meranie** je využité na **korekciu odhadovaných parametrov** (použitie napr. v adaptívnych regulátoroch)

⇒ Predpokladajme, že **poznáme odhad parametrov v N -tom kroku**, získaný z N meraní a **chceme získať odhad v kroku $N+1$**

$$\hat{\boldsymbol{\theta}}_{N+1} = f(\hat{\boldsymbol{\theta}}_N, y_{N+1}, \mathbf{h}_{N+1})$$

3.3.2.1 Rekurzívna metóda najmenších štvorcov (RMNS) s váhovaním a exponenciálnym zabúdaním

⇒ Uvažujeme systém opísaný v i -tom experimente **lineárnou regresnou rovnicou**

$$y_i = \theta_0 + \sum_{k=1}^n \theta_k h_{ki} + v_i = \mathbf{h}_i^T \boldsymbol{\theta} + v_i \quad i = 1, 2, \dots, N$$

kde $\mathbf{h}_i^T = \mathbf{f}(\mathbf{u}_i) = (1 \quad h_{1i} \quad h_{2i} \quad \dots \quad h_{ni})$ $\boldsymbol{\theta} = (\theta_0, \theta_1, \dots, \theta_n)^T$

v_i je šum merania s vlastnosťami $E\{v_i\} = 0, \quad E\{v_i^2\} = \sigma^2$

odhad výstupu je $\hat{y}_i = \hat{\theta}_0 + \sum_{k=1}^n \hat{\theta}_k h_{ki} = \mathbf{h}_i^T \hat{\boldsymbol{\theta}}$ $\hat{\boldsymbol{\theta}} = (\hat{\theta}_0, \hat{\theta}_1, \dots, \hat{\theta}_n)^T$

potom v i -tom experimente bude hodnota odchýlky $e_i = y_i - \hat{y}_i = y_i - \mathbf{h}_i^T \hat{\boldsymbol{\theta}}$

Na **výpočet odhadu parametrov použijeme N vzoriek** a označíme ho $\hat{\boldsymbol{\theta}}_N = (\hat{\theta}_0, \hat{\theta}_1, \dots, \hat{\theta}_n)^T$

Označíme vektory $\mathbf{y}_N = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}$ $\hat{\mathbf{y}}_N = \begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_N \end{pmatrix}$ $\mathbf{v}_N = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_N \end{pmatrix}$

$$\mathbf{e}_N = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_N \end{pmatrix} = \mathbf{y}_N - \hat{\mathbf{y}}_N = \mathbf{y}_N - \mathbf{H}_N \hat{\boldsymbol{\theta}}_N \quad \text{kde} \quad \mathbf{H}_N = \begin{pmatrix} 1 & h_{11} & h_{21} & \dots & h_{n1} \\ 1 & h_{12} & h_{22} & \dots & h_{n2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & h_{1N} & h_{2N} & \dots & h_{nN} \end{pmatrix} = \begin{pmatrix} \mathbf{h}_1^T \\ \mathbf{h}_2^T \\ \vdots \\ \mathbf{h}_N^T \end{pmatrix}$$

⇒ Nech $s_i = \lambda^{N-i} w_i$ je **všeobecný váhový koeficient**,

kde $w_i > 0$ je **váhový koeficient**
 $0 < \lambda \leq 1$ je **faktor zabúdania**

Použijeme účelovú funkciu v tvare

$$Q(\hat{\boldsymbol{\theta}}_N) = \sum_{i=1}^N s_i e_i^2 = \sum_{i=1}^N \lambda^{N-i} w_i (y_i - \hat{\boldsymbol{\theta}}_i^T \mathbf{h}_i)^2 = \mathbf{e}_N^T \mathbf{W}_N \mathbf{e}_N$$

kde $\begin{pmatrix} \lambda^{N-1} w_1 & 0 & \dots & 0 \\ 0 & \lambda^{N-2} w_2 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & w_N \end{pmatrix} = \begin{pmatrix} \lambda \mathbf{W}_{N-1} & \mathbf{0} \\ \mathbf{0} & w_N \end{pmatrix} = \mathbf{W}_N > 0$ je **váhová matica**

⇒ **Minimalizácia účelovej funkcie**

$$Q(\hat{\boldsymbol{\theta}}_N) = \mathbf{e}_N^T \mathbf{W}_N \mathbf{e}_N = (\mathbf{y}_N - \mathbf{H}_N \hat{\boldsymbol{\theta}}_N)^T \mathbf{W}_N (\mathbf{y}_N - \mathbf{H}_N \hat{\boldsymbol{\theta}}_N)$$

$$\Downarrow \quad \Downarrow \quad \Downarrow$$

$$\nabla_{\hat{\boldsymbol{\theta}}_N} Q(\hat{\boldsymbol{\theta}}_N) \Big|_{\hat{\boldsymbol{\theta}}_N^*} = -2 \mathbf{H}_N^T \mathbf{W}_N (\mathbf{y}_N - \mathbf{H}_N \hat{\boldsymbol{\theta}}_N^*) = 0$$

⇒ **Optimálny odhad parametrov v N-tom kroku**

kde

$$\begin{aligned} \hat{\boldsymbol{\theta}}_N^* &= (\mathbf{H}_N^T \mathbf{W}_N \mathbf{H}_N)^{-1} \mathbf{H}_N^T \mathbf{W}_N \mathbf{y}_N = \mathbf{P}_N \mathbf{H}_N^T \mathbf{W}_N \mathbf{y}_N = \mathbf{P}_N \mathbf{q}_N \\ \mathbf{P}_N &= (\mathbf{H}_N^T \mathbf{W}_N \mathbf{H}_N)^{-1} = \mathbf{P}_N^T > 0 \\ \mathbf{q}_N &= \mathbf{H}_N^T \mathbf{W}_N \mathbf{y}_N. \end{aligned}$$

⇒ **Optimálny odhad parametrov v (N+1) kroku**

$$\hat{\boldsymbol{\theta}}_{N+1}^* = \mathbf{P}_{N+1} \mathbf{H}_{N+1}^T \mathbf{W}_{N+1} \mathbf{y}_{N+1} = \left[\underbrace{(\mathbf{H}_N^T \quad \mathbf{h}_{N+1}^T) \begin{pmatrix} \lambda \mathbf{W}_N & \mathbf{0} \\ \mathbf{0}^T & w_{N+1} \end{pmatrix} \begin{pmatrix} \mathbf{H}_N \\ \mathbf{h}_{N+1} \end{pmatrix}}_{\mathbf{P}_{N+1}^{-1}} \right]^{-1} (\mathbf{H}_N^T \quad \mathbf{h}_{N+1}^T) \begin{pmatrix} \lambda \mathbf{W}_N & \mathbf{0} \\ \mathbf{0}^T & w_{N+1} \end{pmatrix} \begin{pmatrix} \mathbf{y}_N \\ y_{N+1} \end{pmatrix}$$

Po roznásobení môžeme zapísať maticu \mathbf{P}_{N+1} v tvare

$$\mathbf{P}_{N+1} = (\lambda \mathbf{H}_N^T \mathbf{W}_N \mathbf{H}_N + w_{N+1} \mathbf{h}_{N+1} \mathbf{h}_{N+1}^T)^{-1} = (\lambda \mathbf{P}_N^{-1} + w_{N+1} \mathbf{h}_{N+1} \mathbf{h}_{N+1}^T)^{-1}$$

t.j. **pri rekurzívnom výpočte odhadu parametrov by bolo potrebné počítat inverziu matice.**

Použijeme **Woodburyho lemma o inverzii matíc**

$$(\mathbf{A}^{-1} + \mathbf{B} \mathbf{C}^{-1} \mathbf{B}^T)^{-1} = \mathbf{A} - \mathbf{A} \mathbf{B} (\mathbf{C} + \mathbf{B}^T \mathbf{A} \mathbf{B})^{-1} \mathbf{B}^T \mathbf{A}$$

Ak bude

$$\mathbf{A}^{-1} = \lambda \mathbf{P}_N^{-1} \quad \mathbf{B} = \mathbf{h}_{N+1} \quad \mathbf{C} = w_{N+1}^{-1}$$

potom

$$\mathbf{P}_{N+1} = \lambda^{-1} \mathbf{P}_N - \underbrace{\lambda^{-1} \mathbf{P}_N \mathbf{h}_{N+1} \left(w_{N+1}^{-1} + \mathbf{h}_{N+1}^T \lambda^{-1} \mathbf{P}_N \mathbf{h}_{N+1} \right)^{-1} \mathbf{h}_{N+1}^T \lambda^{-1} \mathbf{P}_N}_{\text{skalár}}$$

$$\frac{\frac{1}{\lambda} \mathbf{P}_N \mathbf{h}_{N+1}}{\frac{1}{w_{N+1}} + \frac{1}{\lambda} \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1}} = \frac{w_{N+1} \mathbf{P}_N \mathbf{h}_{N+1}}{\lambda + w_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1}} = \mathbf{Y}_{N+1}$$

a dostaneme **rekurzívny vzťah pre výpočet disperznej matice bez potreby invertovať matice väčších rozmerov**

$$\mathbf{P}_{N+1} = \frac{1}{\lambda} (\mathbf{P}_N - \mathbf{Y}_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N) = \frac{1}{\lambda} (\mathbf{I} - \mathbf{Y}_{N+1} \mathbf{h}_{N+1}^T) \mathbf{P}_N$$

kde \mathbf{Y}_{N+1} je **korekčný faktor**

$$\mathbf{Y}_{N+1} = \frac{w_{N+1} \mathbf{P}_N \mathbf{h}_{N+1}}{\lambda + w_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1}} = \rho_{N+1} \mathbf{d}_{N+1}$$

$$\rho_{N+1} = (\lambda + w_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1})^{-1} \quad \text{skalár}$$

$$\mathbf{d}_{N+1} = w_{N+1} \mathbf{P}_N \mathbf{h}_{N+1} \quad \text{vektor}$$

Vzťah pre \mathbf{P}_{N+1} dosadíme do vzťahu pre **optimálny odhad parametrov v (N+1) kroku**

$$\hat{\boldsymbol{\theta}}_{N+1}^* = \mathbf{P}_{N+1} \mathbf{H}_{N+1}^T \mathbf{W}_{N+1} \mathbf{y}_{N+1}$$

Po úprave dostaneme

$$\hat{\boldsymbol{\theta}}_{N+1}^* = \hat{\boldsymbol{\theta}}_N^* + \mathbf{Y}_{N+1} (\mathbf{y}_{N+1} - \mathbf{h}_{N+1}^T \hat{\boldsymbol{\theta}}_N^*) = \hat{\boldsymbol{\theta}}_N^* + \mathbf{Y}_{N+1} \mathbf{e}_{N+1}$$

<div style="display: flex; align-items: center; justify-content: center;"> <div style="text-align: right; margin-right: 10px;">nový odhad</div> <div style="text-align: center; margin-right: 10px;">=</div> <div style="text-align: right; margin-right: 10px;">starý odhad</div> <div style="text-align: center; margin-right: 10px;">+</div> <div style="text-align: right; margin-right: 10px;">vektor korekcií</div> <div style="text-align: center; margin-right: 10px;">·</div> <div style="display: flex; align-items: center;"> <div style="text-align: center; margin-right: 10px;"> <div style="border-left: 1px solid black; border-right: 1px solid black; padding: 0 5px;"> <div style="text-align: center;">nová nameraná hodnota výstupu</div> </div> <div style="text-align: center;">-</div> <div style="border-left: 1px solid black; border-right: 1px solid black; padding: 0 5px;"> <div style="text-align: center;">hodnota výstupu odhadovaná pomocou parametrov z minulého kroku</div> </div> </div> </div> </div>

t.j. **nový odhad získame korekciou predchádzajúceho odhadu**, pričom \mathbf{e}_{N+1} je **odchýlka (rezíduum)**

$$\mathbf{e}_{N+1} = \mathbf{y}_{N+1} - \mathbf{h}_{N+1}^T \hat{\boldsymbol{\theta}}_N^*$$

Hodnota účelovej funkcie (bez odvodu)

$$Q(\hat{\boldsymbol{\theta}}_{N+1}^*) = \lambda \left(Q(\hat{\boldsymbol{\theta}}_N^*) + \frac{w_{N+1} \mathbf{e}_{N+1}^2}{\lambda + w_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1}} \right) = \lambda \left(Q(\hat{\boldsymbol{\theta}}_N^*) + \rho_{N+1} w_{N+1} \mathbf{e}_{N+1}^2 \right)$$

⇒ **Algoritmus RMNŠ bez váhovania a zabúdania (prostá MNŠ)**

$$\lambda = 1 \quad a \quad w_i = 1$$

Z predchádzajúceho kroku poznáme \mathbf{P}_N , $\hat{\boldsymbol{\theta}}_N^*$

V aktuálnom kroku nameriame y_{N+1} ako odozvu na \mathbf{h}_{N+1}

Zosilnenie	$\begin{cases} \text{čitateľ:} \\ \text{menovateľ:} \end{cases} \quad \mathbf{Y}_{N+1} = \rho_{N+1} \mathbf{d}_{N+1} \quad \begin{cases} \mathbf{d}_{N+1} = \mathbf{P}_N \mathbf{h}_{N+1} \\ \rho_{N+1} = (1 + \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1})^{-1} \end{cases}$
Odchýlka:	$\mathbf{e}_{N+1} = y_{N+1} - \mathbf{h}_{N+1}^T \hat{\boldsymbol{\theta}}_N^*$
Nový odhad parametrov:	$\hat{\boldsymbol{\theta}}_{N+1}^* = \hat{\boldsymbol{\theta}}_N^* + \rho_{N+1} \mathbf{e}_{N+1} \mathbf{d}_{N+1} = \hat{\boldsymbol{\theta}}_N^* + \mathbf{e}_{N+1} \mathbf{Y}_{N+1}$
Nová disperzná matica:	$\mathbf{P}_{N+1} = \mathbf{P}_N - \rho_{N+1} \mathbf{d}_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N = \mathbf{P}_N - \mathbf{Y}_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N$
Nová hodnota kritéria:	$Q(\hat{\boldsymbol{\theta}}_{N+1}^*) = Q(\hat{\boldsymbol{\theta}}_N^*) + \rho_{N+1} \mathbf{e}_{N+1}^2 = Q(\hat{\boldsymbol{\theta}}_N^*) + \frac{\mathbf{e}_{N+1}^2}{1 + \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1}}$

 **Príklad** → *priklad_rekurz_met.pdf + cvičenia*

⇒ **Algoritmus RMNŠ bez váhovania so zabúdaním**

$$w_i = 1 \text{ a } s_i = \lambda^{N-i}.$$

Potom sa **zmenia** vzťahy

$\mathbf{Y}_{N+1} = \rho_{N+1} \mathbf{d}_{N+1} = \frac{\mathbf{P}_N \mathbf{h}_{N+1}}{\lambda + \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1}}$ $\mathbf{P}_{N+1} = \frac{1}{\lambda} (\mathbf{P}_N - \mathbf{Y}_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N)$ $Q(\hat{\boldsymbol{\theta}}_{N+1}^*) = \lambda \left(Q(\hat{\boldsymbol{\theta}}_N^*) + \frac{\mathbf{e}_{N+1}^2}{\lambda + \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1}} \right)$

Ostatné vzťahy zostanú **bez zmeny**

$\mathbf{e}_{N+1} = y_{N+1} - \mathbf{h}_{N+1}^T \hat{\boldsymbol{\theta}}_N^*$ $\hat{\boldsymbol{\theta}}_{N+1}^* = \hat{\boldsymbol{\theta}}_N^* + \mathbf{Y}_{N+1} (y_{N+1} - \mathbf{h}_{N+1}^T \hat{\boldsymbol{\theta}}_N^*) = \hat{\boldsymbol{\theta}}_N^* + \mathbf{e}_{N+1} \mathbf{Y}_{N+1}$

Konštantné exponenciálne zabúdanie $\lambda = \text{konšt}$ – postupné **zabúdanie starších údajov**, pričom **najväčšia váha je na poslednom meraní**. Je vhodné v prípade, že sa parametre systému pomaly menia.

Ak sú parametre systému približne konštantné počas T_0 periód vzorkovania, potom faktor zabúdania môže byť zvolený tak, aby vyhovoval vzťahu $T_0 = \frac{1}{1-\lambda}$.

Typické hodnoty λ sú z intervalu 0,98 až 0,995.

Premenlivé exponenciálne zabúdanie $\lambda(t) \rightarrow 1$ – zabúdanie počiatkových údajov. Je vhodné pre stacionárne systémy v prípade **nevhodných počiatkových podmienok**. Napr.

$$\lambda(t) = \lambda_0 \lambda(t-1) + (1-\lambda_0) \lambda_\infty \quad \lambda(0), \lambda_0 \in \langle 0.95; 0.99 \rangle$$

 **Negatívum:**

Ak **vstupy** \mathbf{h}_{k+1} pre $k \geq N$ neprinášajú **novú informáciu**, potom

$$\mathbf{P}_k \mathbf{h}_{k+1} = 0 \quad \rightarrow \quad \mathbf{Y}_{N+1} = 0 \quad \rightarrow \quad \mathbf{P}_{N+1} = \frac{1}{\lambda} \mathbf{P}_N$$

pre $\lambda \in \langle 0.95; 0.99 \rangle$ budú prvky matice **P** narastať geometrickým radom s kvocientom λ^{-1} , t.j. nastáva tzv. „**bursting**“ **disperznej matice**.

Exponenciálne **zabúdanie funguje správne** len ak sú vstupno/výstupné **údaje dostatočne vybudzujúce (prinášajú nové informácie)**. V opačnom prípade budú prvky kovariančnej matice aj zosilnenie identifikácie narastať a **príchod novej informácie môže spôsobiť prudkú (neadekvátnu) zmenu identifikovaných parametrov**.

⇒ **Algoritmus RMNS bez zabúdania s váhovaním**, t.j. $\lambda = 1$ a $s_i = w_i$

$$w_{N+1} = 1 - \varepsilon \frac{e_{N+1}^2}{1 + \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1}} \quad \text{kde} \quad 0.001 \leq \varepsilon \leq 0.01$$

Zmenia sa vzťahy

$$\begin{aligned} \mathbf{y}_{N+1} &= \rho_{N+1} \mathbf{d}_{N+1} = \frac{w_{N+1} \mathbf{P}_N \mathbf{h}_{N+1}}{1 + w_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1}} \\ \mathbf{P}_{N+1} &= \mathbf{P}_N - \mathbf{y}_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N \\ Q(\hat{\boldsymbol{\theta}}_{N+1}^*) &= Q(\hat{\boldsymbol{\theta}}_N^*) + \frac{w_{N+1} e_{N+1}^2}{1 + w_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1}} \end{aligned}$$

Bez zmeny

$$\begin{aligned} e_{N+1} &= y_{N+1} - \mathbf{h}_{N+1}^T \hat{\boldsymbol{\theta}}_N^* \\ \hat{\boldsymbol{\theta}}_{N+1}^* &= \hat{\boldsymbol{\theta}}_N^* + e_{N+1} \mathbf{y}_{N+1} \end{aligned}$$

⇒ **Vlastnosti odhadu $\hat{\boldsymbol{\theta}}_N^*$ pre RMNS**

BLUE (Best Linear Unbiased Estimator):

- lineárny vzhľadom k dátam
- nevychýlený (unbiased)
- výdatný (best, minimum variace)

Linearita

$$\hat{\boldsymbol{\theta}}_N^* = (\mathbf{H}_N^T \mathbf{W}_N \mathbf{H}_N)^{-1} \mathbf{H}_N^T \mathbf{W}_N \mathbf{y}_N = \mathbf{P}_N \mathbf{H}_N^T \mathbf{W}_N \mathbf{y}_N = \mathbf{L}_N \mathbf{y}_N$$

odhad je lineárny vzhľadom k nameraným výstupom.

Nevychýlenosť

$$\hat{\boldsymbol{\theta}}_N^* - \boldsymbol{\theta} = (\mathbf{H}_N^T \mathbf{W}_N \mathbf{H}_N)^{-1} \mathbf{H}_N^T \mathbf{W}_N \mathbf{y}_N - \boldsymbol{\theta} = (\mathbf{H}_N^T \mathbf{W}_N \mathbf{H}_N)^{-1} \mathbf{H}_N^T \mathbf{W}_N (\mathbf{y}_N - \mathbf{H}_N \boldsymbol{\theta}) = \mathbf{P}_N \mathbf{H}_N^T \mathbf{W}_N \mathbf{v}_N$$

$$\hat{\boldsymbol{\theta}}_N^* = \boldsymbol{\theta} + \mathbf{P}_N \mathbf{H}_N^T \mathbf{W}_N \mathbf{v}_N \Rightarrow E\{\hat{\boldsymbol{\theta}}_N^*\} = \boldsymbol{\theta} + \mathbf{P}_N \mathbf{H}_N^T \mathbf{W}_N E\{\mathbf{v}_N\} = \boldsymbol{\theta}$$

odhad je nevychýlený za predpokladu, že $E\{\mathbf{v}_i\} = 0 \quad i = 1, 2, \dots, N$.

Výdatnosť

$$\text{cov}(\hat{\boldsymbol{\theta}}_N) = E\{(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta})(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta})^T\} = \mathbf{P}_N \mathbf{H}_N^T \mathbf{W}_N E\{\mathbf{v}_N \mathbf{v}_N^T\} \mathbf{W}_N \mathbf{H}_N \mathbf{P}_N = \underbrace{\mathbf{P}_N \mathbf{H}_N^T \mathbf{W}_N \text{cov}(\mathbf{v}_N) \mathbf{W}_N \mathbf{H}_N \mathbf{P}_N}_{\mathbf{B}^T \mathbf{B}}$$

Využijeme Schwarzovu nerovnosť

$$\mathbf{B}^T \mathbf{B} \geq \mathbf{B}^T \mathbf{A} (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{B}$$

$$\text{Nech} \quad \mathbf{B} = \sqrt{\text{cov}(\mathbf{v}_N)} \mathbf{W}_N \mathbf{H}_N \mathbf{P}_N = \sqrt{\text{cov}(\mathbf{v}_N)} \mathbf{W}_N \mathbf{H}_N (\mathbf{H}_N^T \mathbf{W}_N \mathbf{H}_N)^{-1}$$

$$\text{Zvolíme } \mathbf{A} \text{ tak, aby platilo } \mathbf{B}^T \mathbf{A} = \mathbf{A}^T \mathbf{B} = \mathbf{I} \Rightarrow \mathbf{A} = \frac{1}{\sqrt{\text{cov}(\mathbf{v}_N)}} \mathbf{H}_N$$

potom
$$\text{cov}(\hat{\theta}_N) = \underbrace{\mathbf{P}_N \mathbf{H}_N^T \mathbf{W}_N \text{cov}(\mathbf{v}_N) \mathbf{W}_N \mathbf{H}_N \mathbf{P}_N}_{\mathbf{P}_N \mathbf{P}_N^{-1} \mathbf{P}_N} \geq (\mathbf{A}^T \mathbf{A})^{-1} = \underbrace{(\mathbf{H}_N^T \text{cov}(\mathbf{v}_N)^{-1} \mathbf{H}_N)^{-1}}_{\mathbf{P}_N}$$

Ak $\mathbf{W}_N = \text{cov}(\mathbf{v}_N)^{-1}$ potom platí rovnosť

$$\text{cov}(\hat{\theta}_N) = (\mathbf{H}_N^T \text{cov}(\mathbf{v}_N)^{-1} \mathbf{H}_N)^{-1} \quad \text{t.j. nadobúda najmenšiu hodnotu.}$$

Odhad $\hat{\theta}_N^* = (\mathbf{H}_N^T \text{cov}(\mathbf{v}_N)^{-1} \mathbf{H}_N)^{-1} \mathbf{H}_N^T \text{cov}(\mathbf{v}_N)^{-1} \mathbf{y}_N$ je výdatný.

⇒ Pri rekurzívnych algoritmoch je potrebné **zvoliť počiatočné podmienky**:

Štartovacia disperzná matica môže byť zvolená ako

$$\mathbf{P}_0 = \lim_{\alpha \rightarrow \infty} \alpha \mathbf{I} \quad 10^4 \leq \alpha \leq 10^{24}$$

a **vektor odhadu parametrov** môže byť inicializovaný ako

$$\hat{\theta}_0^* = 0$$


alebo

$$\mathbf{P}_N = (\mathbf{H}_N^T \mathbf{H}_N)^{-1}$$

využijeme prvých N vzoriek ako jednorazový odhad, je potrebná inverzia matice

a $\hat{\theta}_N^* = \mathbf{P}_N \mathbf{H}_N^T \mathbf{y}_N$ v rekurzívnom výpočte pokračujeme od vzorky N+1

3.3.2.2 Odmocninová verzia rekurzívnej metódy najmenších štvorcov



⇒ Pri použití algoritmu RMNS sa môže stať, že v dôsledku zaokrúhľovania sa **naruší symetria disperznej matice**, čo môže spôsobiť **stratu jej pozitívnej definitnosti** a ovplyvniť konvergenciu odhadu parametrov.

Ak $\mathbf{P}_{N-1} > 0$ bude aj $\mathbf{P}_N = (\mathbf{I} - \rho_N \mathbf{d}_N \mathbf{h}_N^T) \mathbf{P}_{N-1} > 0$?

⇒ Preto je vhodnejšie použiť odmocninovú verziu RMNS.

Keď \mathbf{P}_N je **symetrická a kladne definitná** matica, je možné ju **vyjadriť pomocou jej odmocniny**, ktorú označíme \mathbf{G}_N a na ňu sa už také prísne podmienky nekladú

$$\mathbf{P}_N = \mathbf{G}_N^T \mathbf{G}_N > 0$$

\mathbf{G}_N je **odmocnina (koreň) matice \mathbf{P}_N**

Definujeme $\mathbf{z}_{N+1} = \mathbf{G}_N \mathbf{h}_{N+1}$

potom $\mathbf{d}_{N+1} = \mathbf{P}_N \mathbf{h}_{N+1} = \mathbf{G}_N^T \mathbf{G}_N \mathbf{h}_{N+1} = \mathbf{G}_N^T \mathbf{z}_{N+1}$

a ďalšie vzťahy pre RMNŠ budú mať tvar

$$\begin{aligned}\rho_{N+1} &= (1 + \mathbf{h}_{N+1}^T \mathbf{P}_N \mathbf{h}_{N+1})^{-1} = (1 + \mathbf{h}_{N+1}^T \mathbf{G}_N^T \mathbf{G}_N \mathbf{h}_{N+1})^{-1} = (1 + \mathbf{z}_{N+1}^T \mathbf{z}_{N+1})^{-1} \\ \mathbf{e}_{N+1} &= y_{N+1} - \mathbf{h}_{N+1}^T \hat{\boldsymbol{\theta}}_N^* \\ \hat{\boldsymbol{\theta}}_{N+1}^* &= \hat{\boldsymbol{\theta}}_N^* + \rho_{N+1} \mathbf{d}_{N+1} \mathbf{e}_{N+1} = \hat{\boldsymbol{\theta}}_N^* + \rho_{N+1} \mathbf{e}_{N+1} \mathbf{G}_N^T \mathbf{z}_{N+1} \\ Q(\hat{\boldsymbol{\theta}}_{N+1}^*) &= Q(\hat{\boldsymbol{\theta}}_N^*) + \rho_{N+1} \mathbf{e}_{N+1}^2\end{aligned}$$

Potrebujeme ešte **rekurentný vzťah** pre \mathbf{G}_{N+1}

$$\begin{aligned}\mathbf{P}_{N+1} &= \mathbf{G}_{N+1}^T \mathbf{G}_{N+1} = \mathbf{P}_N - \rho_{N+1} \mathbf{d}_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N = \mathbf{G}_N^T \mathbf{G}_N - \rho_{N+1} \mathbf{G}_N^T \mathbf{G}_N \mathbf{h}_{N+1} \mathbf{h}_{N+1}^T \mathbf{G}_N^T \mathbf{G}_N = \\ &= \mathbf{G}_N^T (\mathbf{I} - \rho_{N+1} \mathbf{z}_{N+1} \mathbf{z}_{N+1}^T) \mathbf{G}_N\end{aligned}$$

Platí $\mathbf{I} - \rho_{N+1} \mathbf{z}_{N+1} \mathbf{z}_{N+1}^T = \left(\mathbf{I} - \frac{\rho_{N+1}}{1 + \sqrt{\rho_{N+1}}} \mathbf{z}_{N+1} \mathbf{z}_{N+1}^T \right)^2$

potom $\mathbf{G}_{N+1} = \left(\mathbf{I} - \frac{\rho_{N+1}}{1 + \sqrt{\rho_{N+1}}} \mathbf{z}_{N+1} \mathbf{z}_{N+1}^T \right) \mathbf{G}_N$

⇒ **Počiatkové podmienky**

$$\mathbf{G}_0 = (10^2 \div 10^{12}) \mathbf{I}$$

alebo využijeme jednorazový odhad z prvých N vzoriek

$$\mathbf{P}_N = \mathbf{G}_N^T \mathbf{G}_N = (\mathbf{H}_N^T \mathbf{H}_N)^{-1} \rightarrow \mathbf{G}_N = (\mathbf{H}_N^T)^{-1}$$

$$\hat{\boldsymbol{\theta}}_N^* = \mathbf{G}_N^T \mathbf{G}_N \mathbf{H}_N^T \mathbf{y}_N$$

alebo na určenie matice \mathbf{G}_N v tvare **hornej trojuholníkovej matice** môžeme použiť **Choleského algoritmus**

$$\mathbf{P}_N = \begin{pmatrix} p_{11} & p_{12} & \dots & p_{1n} \\ p_{12} & p_{22} & \dots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{1n} & p_{2n} & \dots & p_{nn} \end{pmatrix} = \begin{pmatrix} g_{11} & 0 & \dots & 0 \\ g_{12} & g_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ g_{1n} & g_{2n} & \dots & g_{nn} \end{pmatrix} \begin{pmatrix} g_{11} & g_{12} & \dots & g_{1n} \\ 0 & g_{22} & \dots & g_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & g_{nn} \end{pmatrix} = \mathbf{G}_N^T \mathbf{G}_N$$

1. $g_{11} = \pm \sqrt{p_{11}}$
2. $g_{1j} = \frac{1}{g_{11}} p_{1j} \quad j = 2, 3, \dots, n$
3. $g_{ii} = \pm \sqrt{p_{ii} - \sum_{k=1}^{i-1} g_{ki}^2} \quad i = 2, 3, \dots, n$
4. $g_{ij} = \frac{1}{g_{ii}} \left(p_{ij} - \sum_{k=1}^{i-1} g_{ki} g_{kj} \right) \quad j = i+1, \dots, n$

✓ **Postup:**

	Základná verzia	Odmocninová verzia
1. Štart	$\mathbf{P}_0 = (10^4 \div 10^{24})\mathbf{I}, \quad \hat{\boldsymbol{\theta}}_0^* = 0$ alebo $\mathbf{P}_N = (\mathbf{H}_N^T \mathbf{H}_N)^{-1}, \quad \hat{\boldsymbol{\theta}}_N^* = \mathbf{P}_N \mathbf{H}_N^T \mathbf{y}_N$	$\mathbf{G}_0 = (10^2 \div 10^{12})\mathbf{I}, \quad \hat{\boldsymbol{\theta}}_0^* = 0$ alebo $\mathbf{G}_N = (\mathbf{H}_N^T)^{-1}, \quad \hat{\boldsymbol{\theta}}_N^* = \mathbf{G}_N^T \mathbf{G}_N \mathbf{H}_N^T \mathbf{y}_N$
2. Odchýlka (reziduum)	$\mathbf{e}_{N+1} = \mathbf{y}_{N+1} - \mathbf{h}_{N+1}^T \hat{\boldsymbol{\theta}}_N^*$	$\mathbf{e}_{N+1} = \mathbf{y}_{N+1} - \mathbf{h}_{N+1}^T \hat{\boldsymbol{\theta}}_N^*$
3. Vektor zosilnenia	$\mathbf{d}_{N+1} = \mathbf{P}_N \mathbf{h}_{N+1}$	$\mathbf{z}_{N+1} = \mathbf{G}_N \mathbf{h}_{N+1}$
4. Skalár	$\rho_{N+1} = (1 + \mathbf{h}_{N+1}^T \mathbf{d}_{N+1})^{-1}$	$\rho_{N+1} = (1 + \mathbf{z}_{N+1}^T \mathbf{z}_{N+1})^{-1}$
5. Nový odhad	$\hat{\boldsymbol{\theta}}_{N+1}^* = \hat{\boldsymbol{\theta}}_N^* + \rho_{N+1} \mathbf{e}_{N+1} \mathbf{d}_{N+1}$	$\hat{\boldsymbol{\theta}}_{N+1}^* = \hat{\boldsymbol{\theta}}_N^* + \rho_{N+1} \mathbf{e}_{N+1} \mathbf{G}_N^T \mathbf{z}_{N+1}$
6. Nová disperzná matica	$\mathbf{P}_{N+1} = \mathbf{P}_N - \rho_{N+1} \mathbf{d}_{N+1} \mathbf{h}_{N+1}^T \mathbf{P}_N$	$\mathbf{G}_{N+1} = \mathbf{G}_N - \frac{\rho_{N+1}}{1 + \sqrt{\rho_{N+1}}} \mathbf{z}_{N+1} \mathbf{z}_{N+1}^T \mathbf{G}_N$
7. Nová účelová funkcia	$Q(\hat{\boldsymbol{\theta}}_{N+1}^*) = Q(\hat{\boldsymbol{\theta}}_N^*) + \rho_{N+1} \mathbf{e}_{N+1}^2$	$Q(\hat{\boldsymbol{\theta}}_{N+1}^*) = Q(\hat{\boldsymbol{\theta}}_N^*) + \rho_{N+1} \mathbf{e}_{N+1}^2$

📄 **Príklad** → *priklad_rekurz_met.pdf + cvičenia*

3.3.2.3 Rekurzívne algoritmy V. Peterku

⇒ Václav Peterka vytvoril dvojicu rekurzívnych algoritmov REFIL a LDFIL, ktoré umožňujú **získať optimálny odhad parametrov $\hat{\boldsymbol{\theta}}_N^*$ bez požiadavky na invertovanie matíc.**

Vyjadríme **chybu predikcie v k-tom kroku** ako súčin dvoch vektorov

$$\mathbf{e}_k = \mathbf{y}_k - \mathbf{h}_k^T \hat{\boldsymbol{\theta}}_k = - \begin{bmatrix} \mathbf{h}_k^T & \mathbf{y}_k \end{bmatrix} \begin{bmatrix} \hat{\boldsymbol{\theta}}_k \\ -1 \end{bmatrix} = \mathbf{z}_k^T \mathbf{c} \quad k = 1, \dots, N \quad N \gg 1 + \dim(\hat{\boldsymbol{\theta}})$$

kde $\mathbf{z}_k = \begin{bmatrix} \mathbf{h}_k^T & \mathbf{y}_k \end{bmatrix}^T$ $\mathbf{c} = \begin{bmatrix} \hat{\boldsymbol{\theta}}_k & -1 \end{bmatrix}^T$

Potom **preurčený systém rovníc** vyjadríme v tvare

$$\mathbf{e}_N = \mathbf{Z}_N \mathbf{c}$$

$$\mathbf{e}_N = \begin{pmatrix} \mathbf{e}_1 \\ \mathbf{e}_2 \\ \vdots \\ \mathbf{e}_N \end{pmatrix} \quad \mathbf{y}_N = \begin{pmatrix} \mathbf{y}_1 \\ \mathbf{y}_2 \\ \vdots \\ \mathbf{y}_N \end{pmatrix} \quad \mathbf{Z}_N = [\mathbf{H}_N \quad \mathbf{y}_N] = \begin{pmatrix} \mathbf{z}_1^T \\ \mathbf{z}_2^T \\ \vdots \\ \mathbf{z}_N^T \end{pmatrix}$$

Účelovú funkciu vyjadríme v tvare

$$Q(\mathbf{c}) = \sum_{i=1}^N \mathbf{e}_i^2 = \mathbf{e}_N^T \mathbf{e}_N = \mathbf{c}^T \mathbf{Z}_N^T \mathbf{Z}_N \mathbf{c} = \mathbf{c}^T \sum_{i=1}^N (\mathbf{z}_i \mathbf{z}_i^T) \mathbf{c} = \mathbf{c}^T \mathbf{V}_N \mathbf{c}$$

$$\mathbf{V}_N = \sum_{i=1}^N \mathbf{z}_i \mathbf{z}_i^T = \sum_{i=1}^{N-1} \mathbf{z}_i \mathbf{z}_i^T + \mathbf{z}_N \mathbf{z}_N^T = \mathbf{V}_{N-1} + \mathbf{z}_N \mathbf{z}_N^T$$

Ak by sme uvažovali aj parameter zabúdania λ , potom

$$Q(\mathbf{c}) = \sum_{i=1}^N (\lambda^{N-i} \mathbf{e}_i)^T \mathbf{c} = \mathbf{c}^T \sum_{i=1}^N (\lambda^{2(N-i)} \mathbf{z}_i \mathbf{z}_i^T) \mathbf{c} = \mathbf{c}^T \mathbf{V}_N \mathbf{c}$$

$$\mathbf{V}_N = \lambda^2 \mathbf{V}_{N-1} + \mathbf{z}_N \mathbf{z}_N^T$$

Potrebuje inverziu matice \mathbf{V}_N , definujeme **kladne definitnú maticu** \mathbf{R}_N

$$(\mathbf{V}_N)^{-1} = \mathbf{R}_N$$

Požiadavku **kladnej definitnosti matice** \mathbf{R}_N splnil Peterka vo svojich **algoritmoch REFIL a LDFIL** tak, že realizoval **odmocninový rozklad** alebo **LDL rozklad matice** \mathbf{R}_N .

a) Algoritmus REFIL

⇒ Predpokladá, že \mathbf{G}_N je **dolnou trojuholníkovou maticou** v tvare

$$\mathbf{R}_N = \mathbf{G}_N^T \mathbf{G}_N = \mathbf{R}_N^T > 0$$

$$\mathbf{G}_N = \begin{pmatrix} \boldsymbol{\Gamma} & \mathbf{0} \\ \mathbf{g}^T & \gamma \end{pmatrix}$$

Optimálny odhad parametrov potom bude

$$\hat{\boldsymbol{\theta}}_N^* = -\frac{\mathbf{g}}{\gamma}$$

a **hodnota účelovej funkcie**

$$Q(\hat{\boldsymbol{\theta}}_N^*) = \frac{1}{\gamma^2}$$

⇒ Potrebuje **rekurzívny vzťah pre výpočet matice** \mathbf{G}_N

Označme

$$\mathbf{f}_N = \mathbf{G}_{N-1} \mathbf{z}_N = [f_1, f_2, \dots, f_n]^T$$

potom

$$\mathbf{G}_N = \mathbf{W}_{N-1} \frac{\mathbf{G}_{N-1}}{\lambda} = \begin{pmatrix} \frac{s_0}{\lambda} & 0 & \dots & 0 \\ -\frac{f_1 f_2}{s_1 s_2} & \frac{s_1}{s_2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{f_1 f_n}{s_{n-1} s_n} & -\frac{f_2 f_n}{s_{n-1} s_n} & \dots & \frac{s_{n-1}}{s_n} \end{pmatrix} \frac{\mathbf{G}_{N-1}}{\lambda}$$

kde

$$s_0^2 = \lambda^2$$

$$s_q^2 = \lambda^2 + \sum_{k=1}^q f_k^2 = s_{q-1}^2 + f_q^2 \quad q=1, \dots, n$$

$$s_n^2 = \lambda^2 + \mathbf{f}_N^T \mathbf{f}_N$$

$f_i, i=1, \dots, n$ sú prvky vektora \mathbf{f}_N a $n=1 + \dim(\boldsymbol{\theta})$.

Prvky matice \mathbf{G}_N označíme ${}^N g_{ij}$ a vypočítame ich podľa vzťahu (kde ${}^{N-1} g_{ij}$ sú prvky matice

$$\mathbf{G}_{N-1}) \quad {}^N g_{ij} = \frac{1}{\lambda} \frac{s_{i-1}}{s_i} \left({}^{N-1} g_{ij} - \frac{f_i}{s_{i-1}^2} \sum_{k=j}^{i-1} f_k {}^{N-1} g_{kj} \right)$$

⇒ **Štart algoritmu:** \mathbf{G}_N získame **odmocninovým rozkladom** matice \mathbf{R}_N

Kedže platí $r_{ij} = \sum_{k=i}^n g_{ki}^2 \quad i = 1, 2, \dots, n \quad r_{ij} = \sum_{k=i}^n g_{ki} g_{kj} \quad i \geq j$

potom

$$\begin{aligned} g_{nn} &= \sqrt{r_{nn}} & g_{nj} &= \frac{1}{g_{nn}} r_{nj} \text{ pre } j = 1, \dots, n-1 \\ g_{ii} &= \sqrt{r_{ii} - \sum_{k=i+1}^n g_{ki}^2} \text{ pre } i = n-1, \dots, 1 & g_{ij} &= \frac{1}{g_{ii}} \left(r_{ij} - \sum_{k=i+1}^n g_{ki} g_{kj} \right) \text{ pre } j = i-1, \dots, 1 \end{aligned}$$

⇒ Vzťah medzi \mathbf{R}_N a \mathbf{G}_{N-1}

$$\mathbf{R}_N = \mathbf{G}_N^T \mathbf{G}_N = \frac{\mathbf{G}_{N-1}^T}{\lambda} \mathbf{W}_{N-1}^T \mathbf{W}_{N-1} \frac{\mathbf{G}_{N-1}}{\lambda} = \frac{\mathbf{G}_{N-1}^T}{\lambda} \mathbf{M}_{N-1} \frac{\mathbf{G}_{N-1}}{\lambda}$$

☑ **Postup:**

1. Určíme východiskovú maticu \mathbf{R}_N (štvorcová matica rozmeru $n \times n$, kde $n = 1 + \dim(\boldsymbol{\theta})$)

$$\mathbf{Z}_N = [\mathbf{H}_N \mathbf{y}_N] \rightarrow \mathbf{V}_N = \mathbf{Z}_N^T \mathbf{Z}_N = \mathbf{R}_N^{-1} \rightarrow \mathbf{R}_N$$

a zrealizujeme odmocninový rozklad matice \mathbf{R}_N a vypočítame maticu \mathbf{G}_N

$$\begin{aligned} g_{nn} &= \sqrt{r_{nn}} \\ g_{nj} &= \frac{1}{g_{nn}} r_{nj} & j &= 1, \dots, n-1 \\ g_{ii} &= \sqrt{r_{ii} - \sum_{k=i+1}^n g_{ki}^2} & i &= n-1, \dots, 1 \\ g_{ij} &= \frac{1}{g_{ii}} \left(r_{ij} - \sum_{k=i+1}^n g_{ki} g_{kj} \right) & j &= i-1, \dots, 1 \end{aligned}$$

alebo $\mathbf{G}_0 \stackrel{!}{=} (10^2 \div 10^{12}) \mathbf{I} \quad \hat{\boldsymbol{\theta}}_0 \stackrel{!}{=} \mathbf{0}$

2. Vypočítame odhad parametrov a hodnotu účelovej funkcie

Ak $\mathbf{G}_N = \begin{pmatrix} \boldsymbol{\Gamma} & \mathbf{0} \\ \mathbf{g}^T & \gamma \end{pmatrix}$

potom $\hat{\boldsymbol{\theta}}_N = -\frac{\mathbf{g}}{\gamma}$ a $Q(\hat{\boldsymbol{\theta}}_N) = \frac{1}{\gamma^2}$

3. Vypočítame prvky matice \mathbf{W}_N

$$\begin{aligned} \mathbf{z}_{N+1} &= [\mathbf{h}_{N+1}^T \quad y_{N+1}]^T \\ \mathbf{f}_{N+1} &= \mathbf{G}_N \mathbf{z}_{N+1} = [f_1, f_2, \dots, f_n]^T \\ s_0^2 &= \lambda^2 & s_q^2 &= s_{q-1}^2 + f_q^2 & q &= 1, 2, \dots, n \end{aligned}$$

4. Vypočítame prvky novej matice \mathbf{G}_{N+1} a pokračujeme krokom 2.

$${}^{N+1}g_{ij} = \frac{1}{\lambda} \frac{s_{i-1}}{s_i} \left({}^N g_{ij} - \frac{f_i}{s_{i-1}^2} \sum_{m=j}^{i-1} f_m {}^N g_{mj} \right) \quad \frac{f_i}{s_{i-1}^2} \sum_{m=j}^{i-1} f_m {}^N g_{mj} = 0 \text{ pre } i = j$$

📄 **Príklad** → **priklad_rekurz_met.pdf + cvičenia**

b) Algoritmus LDFIL

⇒ Predpokladá, že **symetrickú pozitívne definitnú** maticu $\mathbf{R}_N = \mathbf{R}_N^T > 0$ **rozložíme na súčin troch matic**

$$\mathbf{R}_N = \mathbf{L}_N^T \mathbf{D}_N \mathbf{L}_N$$

kde $\mathbf{D}_N = \begin{pmatrix} d_1 & 0 & 0 & \dots & 0 \\ 0 & d_2 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & d_{n-1} & 0 \\ 0 & 0 & \dots & 0 & d_n \end{pmatrix}$ $\mathbf{L}_N = \begin{pmatrix} 1 & 0 & \dots & 0 & 0 \\ l_{21} & 1 & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ l_{(n-1)1} & l_{(n-1)2} & \dots & 1 & 0 \\ l_{n1} & l_{n2} & \dots & l_{n(n-1)} & 1 \end{pmatrix}$ $\begin{matrix} l_{ii} = 1 & i = 1, \dots, n \\ l_{ij} = 0 & i > j \end{matrix}$

Označme štruktúru matic nasledovne

$$\mathbf{R}_N = \mathbf{L}_N^T \mathbf{D}_N \mathbf{L}_N = \begin{pmatrix} \mathbf{\Lambda}^T & \boldsymbol{\lambda} \\ \mathbf{0}^T & 1 \end{pmatrix} \begin{pmatrix} \mathbf{\Delta} & \mathbf{0} \\ \mathbf{0}^T & d \end{pmatrix} \begin{pmatrix} \mathbf{\Lambda} & \mathbf{0} \\ \boldsymbol{\lambda}^T & 1 \end{pmatrix}$$

Optimálny odhad parametrov potom bude

$$\hat{\boldsymbol{\theta}}_N^* = -\boldsymbol{\lambda}$$

a **hodnota účelovej funkcie**

$$Q(\hat{\boldsymbol{\theta}}_N^*) = \frac{1}{d}$$

⇒ **Štart algoritmu: $\mathbf{L}^T \mathbf{D} \mathbf{L}$ rozklad** matice \mathbf{R}_N (r_{ij} sú prvky matice \mathbf{R}_N)

Kedže platí $r_{ij} = \sum_{k=i}^n l_{ki} d_k l_{kj} = d_i l_{ij} + \sum_{k=i+1}^n l_{ki} d_k l_{kj}$ $r_{ii} = d_i + \sum_{k=i+1}^n d_k l_{ki}^2$

potom
$$l_{ij} = \frac{1}{d_i} \left(r_{ij} - \sum_{k=i+1}^n l_{ki} d_k l_{kj} \right)$$

$$d_i = r_{ii} - \sum_{k=i+1}^n d_k l_{ki}^2$$

prvky matice \mathbf{L}_N **prvky matice \mathbf{D}_N**

⇒ **Rekurzívne vzťahy** pre matice \mathbf{L}_N a \mathbf{D}_N

Označme $\mathbf{f}_N = \mathbf{L}_{N-1} \mathbf{z}_N$ a f_i označuje i -ty prvok vektora \mathbf{f}_N

potom
$$\mathbf{L}_N = \mathbf{X}_{N-1} \mathbf{L}_{N-1} = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ -\frac{f_2 f_1}{s_1^2} d_1 & 1 & 0 & \dots & 0 \\ -\frac{f_3 f_1}{s_2^2} d_1 & -\frac{f_3 f_2}{s_2^2} d_2 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -\frac{f_n f_1}{s_{n-1}^2} d_1 & -\frac{f_n f_2}{s_{n-1}^2} d_2 & -\frac{f_n f_3}{s_{n-1}^2} d_3 & \dots & 1 \end{pmatrix} \mathbf{L}_{N-1}$$

$$\mathbf{D}_N = \mathbf{U}_{N-1} \mathbf{D}_{N-1} = \begin{pmatrix} \frac{s_0^2}{s_1^2} & 0 & 0 & \dots & 0 \\ 0 & \frac{s_1^2}{s_2^2} & 0 & \dots & 0 \\ 0 & 0 & \frac{s_2^2}{s_3^2} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \frac{s_{n-1}^2}{s_n^2} \end{pmatrix} \frac{\mathbf{D}_{N-1}}{\lambda^2}$$

Prvky matice \mathbf{X}_{N-1} $N-1 x_{ij} = -\frac{f_i f_j d_j}{s_{i-1}^2}$

kde $s_0^2 = \lambda^2$

$$s_q^2 = \lambda^2 + \sum_{k=1}^q d_k f_k^2 = s_{q-1}^2 + d_q f_q^2 \quad q=1, \dots, n$$

$$s_n^2 = \lambda^2 + \mathbf{f}_N^T \mathbf{D}_{N-1} \mathbf{f}_N$$

f_i označuje i -ty prvok vektora \mathbf{f}_N a d_i je i -ty diagonálny prvok matice \mathbf{D}_{N-1} .

Prvky matice \mathbf{L}_N $N l_{ij} = N-1 l_{ij} + \sum_{k=j}^{i-1} N-1 x_{ik} N-1 l_{kj} = N-1 l_{ij} - \frac{f_i}{s_{i-1}^2} \sum_{k=j}^{i-1} f_k N-1 d_k N-1 l_{kj}$

Prvky matice \mathbf{U}_{N-1} $N-1 u_i = \frac{1}{\lambda^2} \frac{s_{i-1}^2}{s_i^2}$

Prvky matice \mathbf{D}_N $N d_i = \frac{1}{\lambda^2} \frac{s_{i-1}^2}{s_i^2} N-1 d_i$

✓ Postup:

1. Určíme východiskovú maticu \mathbf{R}_N (štvorcová matica rozmeru $n \times n$, kde $n = 1 + \dim(\boldsymbol{\theta})$)

$$\mathbf{Z}_N = [\mathbf{H}_N \mathbf{y}_N] \rightarrow \mathbf{V}_N = \mathbf{Z}_N^T \mathbf{Z}_N = \mathbf{R}_N^{-1} \rightarrow \mathbf{R}_N$$

a zrealizujeme $\mathbf{L}^T \mathbf{D} \mathbf{L}$ rozklad matice \mathbf{R}_N , t.j. vypočítame matice \mathbf{L}_N a \mathbf{D}_N

$$d_i = r_{ii} - \sum_{k=i+1}^n d_k l_{ki}^2 \quad i = n, \dots, 1$$

$$l_{ij} = \frac{1}{d_i} \left(r_{ij} - \sum_{k=i+1}^n l_{ki} d_k l_{kj} \right) \quad j = i-1, \dots, 1$$

$$l_{ii} = 1$$

alebo $\mathbf{L}_0 = \mathbf{I}; \quad \mathbf{D}_0 = (10^2 \div 10^{12}) \mathbf{I} \quad \hat{\boldsymbol{\theta}}_0^* = \mathbf{0}$

2. Vypočítame odhad parametrov a hodnotu účelovej funkcie

$$\text{Ak} \quad \mathbf{R}_N = \mathbf{L}_N^T \mathbf{D}_N \mathbf{L}_N = \begin{pmatrix} \boldsymbol{\Lambda}^T & \boldsymbol{\Lambda} \\ \mathbf{0}^T & 1 \end{pmatrix} \begin{pmatrix} \mathbf{\Delta} & \mathbf{0} \\ \mathbf{0}^T & d \end{pmatrix} \begin{pmatrix} \boldsymbol{\Lambda} & \mathbf{0} \\ \boldsymbol{\Lambda}^T & 1 \end{pmatrix}$$

potom $\hat{\boldsymbol{\theta}}_N^* = -\boldsymbol{\Lambda}$

$$Q(\hat{\theta}_N^*) = \frac{1}{d}$$

3. Určíme parametre potrebné na výpočet prvkov matíc \mathbf{X}_N a \mathbf{U}_N

$$\mathbf{f}_{N+1} = \mathbf{L}_N \mathbf{z}_{N+1} \quad \text{kde } \mathbf{z}_{N+1} = \begin{bmatrix} \mathbf{h}_{N+1}^T & y_{N+1} \end{bmatrix}^T \text{ a}$$

$$s_0^2 = \lambda^2$$

$$s_q^2 = \lambda^2 + \sum_{k=1}^q d_k f_k^2 = s_{q-1}^2 + d_q f_q^2 \quad q=1, \dots, n$$

d_i je i -ty diagonálny prvok matice \mathbf{D}_N .

4. Vypočítame prvky nových matíc \mathbf{L}_{N+1} a \mathbf{D}_{N+1} pokračujeme krokom 2.

$${}^{N+1}d_i = {}^N d_i \frac{1}{\lambda^2} \frac{s_{i-1}^2}{s_i^2}$$

$${}^{N+1}l_{ij} = {}^N l_{ij} - \frac{f_i}{s_{i-1}^2} \sum_{m=j}^{i-1} f_m {}^N d_m {}^N l_{mj}$$

 **Príklad** → *priklad_rekurz_met.pdf + cvičenia*