

8 PRAKTICKÉ OTÁZKY IDENTIFIKÁCIE

8.1. Analýza systému

Čo sú vstupy a čo výstupy?

Sú merateľné?

Je možné / dovolené ich aktívne nastavovať?

Periódá vzorkovania?

⇒ Nech T_{vz} je **periódá vzorkovania**, potom $\omega_s = \frac{2\pi}{T_{vz}}$ je **frekvencia vzorkovania** a

$\omega_N = \frac{\omega_s}{2} = \frac{\pi}{T_{vz}}$ je **Nyquistova frekvencia**.

Shannon-Kotelnikovov-Nyquistov teorém: Presná rekonštrukcia spojitého signálu z jeho vzoriek je možná vtedy, ak bol vzorkovaný frekvenciou aspoň dvakrát vyššou ako je maximálna frekvencia rekonštruovaného signálu.

Ak vzorkovaný signál obsahuje frekvencie vyššie ako ω_N , potom budú tieto interpretované ako príspevky od nižších frekvencií – **aliasing** – a rekonštruovaný signál bude odlišný od pôvodného. **Informácia o frekvenciách vyšších ako Nyquistova frekvencia sa pri vzorkovaní stratí.** Preto ak predpokladáme, že signál obsahuje frekvencie vyššie ako ω_N , mal by byť **signál pred vzorkovaním prefiltrovaný** cez tzv. **antialiasing filter**, ktorý príspevky od týchto frekvencií neprepustí.

V prípade zašumeného vstupného signálu **saperiódá vzorkovania zvyčajne volí tak, aby spektrum užitočného signálu bolo pod ω_N** a antialiasing filter potom odfiltruje vysokofrekvenčné príspevky od šumu.

⇒ Teoreticky je najvýhodnejšie vzorkovať tak rýchlo ako je technicky (a ekonomicky) možné.

Avšak pri **príliš malých periódach vzorkovania**:

- môžu nastať numerické problémy a póly identifikovaného modelu sa blížia ku 1,
- zhoda modelu so systémom nastáva skôr vo vysokofrekvenčnej oblasti,
- neeliminuje sa vplyv šumu.

Ak je **periódá vzorkovania príliš veľká**:

- vplyvu šumu je redukovaný, ale
- informácia o dynamike systému je nedostatočná,
- narastá rozptyl identifikovaných parametrov (klesá výdatnosť odhadu).

Je horšie použiť príliš veľkú periódú vzorkovania ako príliš malú. Odporúčaná frekvencia vzorkovania je približne desaťnásobok odhadovaného frekvenčného rozsahu systému. Ak náklady na meranie nie sú vysoké, potom je možné vzorkovať tak rýchlo ako je technicky možné a potom urobiť výber údajov v závislosti od zvolenej periódy vzorkovania.

Ak má model slúžiť na účely návrhu riadenia, **periódá vzorkovania by mala byť rovnaká ako pri riadení.**

8.2. Voľba vstupného signálu

Nominálny pracovný bod nelineárneho systému?

Rozsah pracovnej oblasti systému?

Frekvenčné spektrum a tvar vstupného signálu?

Dĺžka merania (počet vzoriek)?

⇒ **Podmienky experimentu** by sa mali **podobat' pracovným podmienkam**, v ktorých bude model použitý.

⇒ **Vstupný signál** musí mať **dostatočne bohaté frekvenčné spektrum**, aby **v celej oblasti sústavou prenášaných frekvencií** preverovali jej prenosové vlastnosti – t.j. vstupný signál by mal mať konštantný priebeh frekvenčného spektra v tej oblasti frekvencií, kde je modul frekvenčného prenosu identifikovanej sústavy podstatne odlišný od nuly.

Biely šum – konštantný priebeh vlastnej výkonovej spektrálnej hustoty.

⇒ **Nepretržite vybudzujúci (NV) signál rádu n** je taký signál $u(k)$, pre ktorý platí

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N \left(X(z^{-1}) u(k) \right)^2 > 0$$

pre všetky polynómy $X(z^{-1})$ stupňa $n-1$ a menšieho.

Experiment je dostatočne informatívny pre získanie nevychýleného odhadu n parametrov, ak vstupný signál je nepretržite vybudzujúci najmenej rádu n.

Príklady:

1. $u(t)=A=\text{konšt}$ je NV rádu 1.

2. $u(t)=A \sin(\omega t)$ je NV rádu 2.

3. $u(t) = \sum_{k=1}^n A_k \sin(\omega_k t)$ je NV rádu $2n$.

4. Biely šum je NV všetkých rádov.

⇒ Keďže výdatnosť odhadu sa zvyšuje so vzrastom hladiny užitočných signálov, **vstupný signál by mal mať čo najmenší činiteľ výkyvu** C_r (crest factor), ktorý je pre signály s nulovou strednou hodnotou definovaný nasledovne

$$C = \frac{|u|_{\text{peak}}}{u_{\text{rms}}} \quad u_{\text{rms}} = \sqrt{\frac{1}{N} (u(1)^2 + \dots + u(N)^2)}$$

Teoreticky najmenšia hodnota C_r je 1, ktorá je dosiahnutá pre binárny symetrický signál $u(t) = \pm A$.

⇒ **Typické vstupné signály:**

- Filtrovaný Gaussov biely šum – filtrom sa dosiahne požadované frekvenčné spektrum signálu)
- Náhodný binárny signál – môže byť generovaný rôznymi spôsobmi, najpoužívanejší je: biely Gaussov šum s nulovou strednou hodnotou sa prefiltruje cez vhodne zvolený filter a potom sa vezme znamienko filtrovaného signálu
- Pseudonáhodný binárny signál (PRBS) – periodický deterministický signál s vlastnosťami bieleho šumu

$$u(t) = \text{rem}(a_1 u(t-1) + \dots + a_n u(t-n), 2)$$

$\text{rem}(x, 2)$ označuje zvyšok po delení $x/2$, t.j. nadobúda hodnotu 0 alebo 1.

Maximálna dĺžka periódy je $M=2^n-1$.

- Suma sínusoviek – umožňuje vytvoriť spektrum z požadovaných frekvencií

$$u(t) = \sum_{k=1}^d a_k \cos(\omega_k t + \phi_k)$$

Sínusovky by mali byť čo najviac rozfázované, aby mal výsledný signál čo najmenší činiteľ výkyvu.

⇒ Ak sa používajú **periodické signály**, je vhodné urobiť **meranie počas K periód** a na identifikáciu použiť výstupný signál v trvaní jednej periódy získaný ako **priemer zo všetkých periód** – **zniži sa tým vplyv šumu**

$$y_u(t) = \frac{1}{K} \sum_{k=0}^{K-1} y(t + kM) \quad 1 \leq t \leq M \quad M \text{ je perióda signálu}$$

Potom je možné urobiť aj **odhad šumu**:

$$\hat{v}(t) = y(t) - y_u(t)$$

a jeho vlastností, napr. disperzie

$$S_v^2 = \frac{1}{(K-1)M} \sum_{t=1}^{KM} \hat{v}^2(t)$$

8.3. Spracovanie nameraných údajov

Šum?

Ustálené zložky?

Veľkosť signálov?

⇒ **Odstránenie statického posunu** – pri odvodení a analýze vlastností MNŠ sme predpokladali, že šum merania má nulovú strednú hodnotu, čo však v praxi nastáva zriedka. Väčšinou je cieľom identifikovať model opisujúci správanie systému v okolí pracovného bodu (u^s , y^s), preto je potrebné pri identifikácii pracovať s odchýlkovými veličinami

$$\bar{y}(t) = y(t) - y^s \quad \text{a} \quad \bar{u}(t) = u(t) - u^s$$


⇒ **Normalizácia signálov** – ak nadobúdajú signály vstupu a výstupu rádovo rozdielne hodnoty, mohla by byť disperzná matica zle podmienená, čo by mohlo viesť k numerickým problémom. Preto sa signály normalizujú, napr.

$$y'(t) = \frac{y(t)}{y^s}$$

⇒ **Filtrácia signálov** – predpokladajme, že na **užitočný signál** $s(t)$ pôsobí **aditívna porucha** $n(t)$, pričom **merateľný je iba skreslený signál** $y(t)$

$$y(t) = s(t) + n(t)$$

Cieľom je **rekonštruovať užitočný signál a potlačiť poruchu** $n(t)$ pomocou **filtra**



Filtre – technické alebo programové prostriedky na separáciu signálov

Typy filtrov:

a) Podľa technickej realizácie:

- **Analógové** (spojité) – realizované pomocou pasívnych prvkov (RLC články) alebo pomocou aktívnych RC článkov využívajúcich operačné zosilňovače
- **Číslicové** (diskrétné) – implementované ako programy.
 - **FIR** (Finite Impulse Response) filtre – filtre s konečnou impulzovou odpoveďou. Patria medzi najjednoduchšie číslicové filtre ako z teoretického, tak aj z realizačného hľadiska. Medzi charakteristické vlastnosti patrí stabilita a možnosť realizácie FIR filtra s lineárnou fázovou charakteristikou (t.j. proporcionálna frekvencii). Ich prenosová funkcia obsahuje iba čitateľa.
 - **IIR** (Infinite Impulse Response) filtre – filtre s nekonečnou impulzovou odpoveďou. Zvyčajne sa navrhujú ako číslicové verzie analógových filtrov. Majú vnútornú spätnú väzbu a môžu byť nestabilné. Ich prenosová funkcia obsahuje čitateľa aj menovateľa.

b) Podľa frekvenčných charakteristík signálu a šumu:

- **Pásmové** (selektívne) – ak sa spektrá signálu a šumu nachádzajú v rôznych frekvenčných rozsahoch, realizujú sa analógovo alebo číslicovo
 - **dolnopriepustné** (low-pass) filtre
 - **hornopriepustné** (high-pass) filtre
 - **pásmové priepusty** (band-pass filters)
 - **pásmové zádrže** (band-elimination filters)
 - **celopriepustné** (all-pass) filtre (menia iba fázové pomery signálov)

Ideálne verzie filtrov majú v pásme prepúšťania jednotkové zosilnenie (neskreslený prenos) a mimo tohto pásma skokom realizované pásmo prechodu do pásma tlmenia s nulovým zosilnením, ideálne filtre však nie je možné prakticky realizovať.

- **Štatistické metódy** – ak sa spektrá signálu a šumu vzájomne prekrývajú, filtre sa realizujú číslicovo.

8.3.1 Analógové filtre

⇒ **Dolnopriepustné filtre** – filtrujú vysokofrekvenčné šумы v rozsahu $\omega > \omega_0$


- **Sériové zapojenie n členov 1. rádu**

$$G(j\omega) = \frac{1}{(1 + j\omega T)^n} = \frac{1}{(1 + j\Omega)^n}$$

$$\omega_0 = \frac{1}{T} \quad \begin{array}{l} \text{frekvencia zlomu} \\ \text{filtra} \end{array}$$

- **Butterworthov filter (BF)** – má póly na jednotkovej kružnici a jeho amplitúdová charakteristika má tvar

$\Omega = \frac{\omega}{\omega_0} = \omega T$ je normovaná frekvencia



$$|G(j\Omega)| = \frac{1}{\sqrt{1 + \Omega^{2n}}}$$

V pásme prepúšťania je amplitúdová charakteristika rovná.

Na obr. je FCH BF 1. rádu.

- **Čebyševov filter (ČF1) typu 1** – má amplitúdovú charakteristiku v tvare

$$|G(j\Omega)| = \frac{1}{\sqrt{1 + \varepsilon^2 T_n^2(\Omega)}}$$


ε je konštanta a T_n sú Čebyševove polynómy stupňa n .

V pásme prepúšťania amplitúdová charakteristika osciluje medzi

hodnotami 1 a $\frac{1}{\sqrt{1 + \varepsilon^2}}$ (**extremálne**

odchýlky), ale pásmo prechodu má užšie ako BF.

Na obr. je FCH ČF1 4. rádu.



Čebyševov polynóm i -teho stupňa je definovaný nasledovne

$$T_i(x) = \cos(i \cdot \arccos(x)) \quad \text{kde} \quad -1 \leq x \leq 1$$

t.j. frekvenciu treba najskôr **znormovať** do intervalu $\langle -1; 1 \rangle$. S využitím vzorca

$$\cos[(i+1) \cdot \arccos(x)] + \cos[(i-1) \cdot \arccos(x)] = 2 \cos(i \cdot \arccos(x)) \cos(\arccos(x))$$

pre **Čebyševove polynómy** dostávame


$T_0(x) = 1$	$T_{i+1}(x) = 2xT_i(x) - T_{i-1}(x) \quad \text{pre } i \geq 1$ rekurentný vzťah
$T_1(x) = x$	
$T_2(x) = 2x^2 - 1$	
$T_3(x) = 4x^3 - 3x$	
$T_4(x) = 8x^4 - 8x^2 + 1$	

t.j.

- **Čebyševov filter (ČF2) typu 2**

– má amplitúdovú charakteristiku v tvare

$$|G(j\Omega)| = \frac{1}{\sqrt{1 + \frac{1}{\varepsilon^2 T_n^2(\Omega)}}}$$



Amplitúdová charakteristika vykazuje extrémálne odchýlky v pásme tlmenia.


Na obr. je FCH ČF2 5. rádu.

- **Eliptický (Cauerov) filter (EF)** – má amplitúdovú charakteristiku v tvare

$$|G(j\Omega)| = \frac{1}{\sqrt{1 + \varepsilon^2 R_n^2(\xi, \Omega)}}$$

ε a ξ sú konštanty a R_n sú eliptické racionálne funkcie stupňa n .

Amplitúdová charakteristika vykazuje extrémálne odchýlky nielen v pásme prepúšťania, ale aj v pásme tlmenia, avšak filter má najužšie pásmo prechodu spomedzi všetkých filtrov rovnakého rádu.



Na obr. je FCH EF 4. rádu.

 **Príklady** → *priklad_filtre.pdf* + *cvičenia*

Poznámka:

Návrh číslicových filtrov a samotná filtrácia signálov sú jednoducho implementovateľné v **Matlabe** s využitím balíka funkcií na spracovanie signálov - **Signal Processing Toolbox**

- **butter** – návrh dolno- alebo hornopriepustného Butterworthovho filtra
- **cheby1** – návrh doplnopriepustného Čebyševovho filtra typu 1
- **cheby2** – návrh doplnopriepustného Čebyševovho filtra typu 2
- **ellip** – návrh doplnopriepustného eliptického filtra
- **filter** – filtrácia údajov zadaným filtrom
- **fvtool** – GUI na analýzu číslicových filtrov
- **designfilt** – návrh číslicových filtrov

8.3.2 Špeciálne (rekurentné) filtre

⇒ Algoritmy na výpočet **priebežného priemeru hodnôt** filtrovaného signálu a **filtráciu špičiek** náhodných prechmitov

- **Priebežný priemer s nekonečnou pamäťou**
(filtrácia špičiek náhodných prechmitov)

$$\hat{s}(k) = \hat{s}(k-1) + \frac{1}{k} (y(k) - \hat{s}(k-1)) \quad \hat{s}(k) \text{ je odhad filtrovaného signálu v kroku } k$$

- **Priebežný priemer s konštantným koeficientom korekcie**
(špeciálny prípad predchádzajúceho pre $k=k_1=\text{konšt}$)

$$\hat{s}(k) = \hat{s}(k-1) + \frac{1}{k_1} (y(k) - \hat{s}(k-1)) = \frac{k_1-1}{k_1} \hat{s}(k-1) + \frac{1}{k_1} y(k)$$

$$\frac{\hat{s}(z)}{y(z)} = \frac{b_0}{1 + a_1 z^{-1}} \quad b_0 = \frac{1}{k_1} \quad a_1 = \frac{1-k_1}{k_1} \quad \text{dolnopriepustný filter 1. rádu}$$

- **Priebežný priemer s konečnou pamäťou**

(priemeruje sa posledných N meraní)

$$\hat{s}(k) = \hat{s}(k-1) + \frac{1}{N} (y(k) - \hat{s}(k-N))$$

$$\frac{\hat{s}(z)}{y(z)} = \frac{1}{N} \frac{(1 - z^{-N})}{(1 - z^{-1})}$$

 **Príklady** → *priklady_filtrácia_signalov.pdf + cvičenia*

8.4. Určenie štruktúry modelu a validácia modelu

Typ modelu?

Veľkosť modelu?

Kvalita modelu?

⇒ **Voľba vhodnej štruktúry** modelu je **rozhodujúca** pre **úspešnú identifikáciu**. Zahŕňa

- **typ modelu** (lineárny, nelineárny, stavový, vstupno/výstupný,...) – využitie apriórnej informácie, intuície, inžinierskych skúseností, treba začať od najjednoduchších
- **veľkosť modelu** (stupne polynómov, rozmery matic, významnosť vplyvu jednotlivých vstupov,...)

⇒ **Parametrizácia modelu** – treba zvoliť vhodný algoritmus, môžu nastať numerické problémy

⇒ **Vyhodnotenie kvality výsledného modelu**

- **kompromis medzi zložitou a presnosťou modelu**, pričom je dôležité zamýšľané použitie modelu,
- **testovanie na údajoch**, ktoré sú **blízke** predpokladaným **pracovným podmienkam** modelovaného systému.

⇒ **Porovnanie modelov rôznych veľkostí - informačné kritériá:**

- **Konečná chyba predikcie (FPE – Final Prediction Error, Hirotugu Akaike, 1969)**
Miera kvality modelu pre testovanie na iných údajoch ako boli použité na identifikáciu.

$$FPE = V \left(\frac{1 + d/N}{1 - d/N} \right)$$

kde N je počet nameraných údajov

d je počet odhadovaných parametrov

$$V = \frac{1}{N} \sum_{i=1}^N e_i(\hat{\theta}_N)^2 \quad \text{je hodnota účelovej funkcie}$$

Kritérium **kombinuje komplexnosť modelu** (reprezentovaná počtom parametrov) a **kvalitu odhadu parametrov** (hodnota účelovej funkcie).

Najlepší model má najmenšiu hodnotu kritéria.

Pre $d \ll N$

$$\text{FPE} = V \left(1 + 2 \frac{d}{N} \right)$$

- **Akaikeho informačné kritérium** (Akaike Information Criterion – AIC, 1974)

$$\text{AIC} = \ln V + 2 \frac{d}{N}$$

Pre $d \ll N$

$$\text{AIC} = \ln \left(V \left(1 + 2 \frac{d}{N} \right) \right)$$

- **Schwarz-Bayesovo kritérium** (Schwarzovo informačné kritérium (bayesovské); Schwarz information criterion – BIC, SBC, 1978)

$$\text{BIC} = \ln V + \frac{d}{N} \ln N$$

Poznámky:

- AIC je približne rovné $\ln(\text{FPE})$.
- ak sú použité tie isté údaje na identifikáciu aj na validáciu, zvýšenie počtu odhadovaných parametrov vždy vedie k zlepšeniu zhody modelu.
- **Matlab:** *mod.EstimationInfo, fpe, aic, aicbic*.

⇒ **Validácia modelu** - vyhodnotenie či model

- **súhlasí s nameranými dátami**
- **popisuje skutočný proces**
- **je dostatočne dobrý a použiteľný** pre zamýšľaný účel.