

Regresná analýza

1. Odhad parametrov modelu statického systému

Máme nameranú nasledovnú závislosť – počet meraní $N=8$:

i	1	2	3	4	5	6	7	8
u_i	2	4	6	7	8	9	10	12
y_i	8	7	5	4	5	3	2	3

Úlohou je vypočítať odhad parametrov nasledujúcich aproximácií:

a) Lineárna regresia: $\hat{y} = \hat{\theta}_0 + \hat{\theta}_1 u$

b) Kvadratická regresia: $\hat{y} = \hat{\theta}_0 + \hat{\theta}_1 u + \hat{\theta}_2 u^2$

c) Kubická regresia: $\hat{y} = \hat{\theta}_0 + \hat{\theta}_1 u + \hat{\theta}_2 u^2 + \hat{\theta}_3 u^3$

Pre každý typ závislosti **vyčíslit' súčet kvadrátov odchýlok** a na základe nich **určiť poradie vhodnosti náhrady** nameraných údajov.

a) Lineárna regresia

$$\hat{y}_i = \hat{\theta}_0 + \hat{\theta}_1 u_i = \hat{\theta}_0 + \hat{\theta}_1 f_1(u_i) = \begin{bmatrix} \hat{\theta}_0 & \hat{\theta}_1 \end{bmatrix} \begin{bmatrix} 1 \\ f_1(u_i) \end{bmatrix} = \hat{\theta}_1^T \mathbf{f}_1(u_i) \quad \text{pre } i=1, \dots, N$$

$$\hat{\theta}_1 = \begin{pmatrix} \hat{\theta}_0 \\ \hat{\theta}_1 \end{pmatrix}$$

$$\mathbf{f}_1(u_i) = \begin{bmatrix} 1 \\ f_1(u_i) \end{bmatrix} = \begin{bmatrix} 1 \\ u_i \end{bmatrix} \quad k=1$$

Po dosadení u_i do rovnice pre lineárnu regresiu pre $i=1, \dots, N$ dostaneme

$$\hat{y}_1 = \hat{\theta}_0 + \hat{\theta}_1 u_1$$

$$\hat{y}_2 = \hat{\theta}_0 + \hat{\theta}_1 u_2$$

maticovo

$$\hat{\mathbf{y}} = \mathbf{H}_1 \hat{\theta}_1$$

kde

$$\mathbf{H}_1 = \begin{pmatrix} 1 & u_1 \\ 1 & u_2 \\ \vdots & \vdots \\ 1 & u_N \end{pmatrix}$$

$$\hat{y}_N = \hat{\theta}_0 + \hat{\theta}_1 u_N$$

Maticu \mathbf{H}_1 dosadíme do Gaussovho vzťahu spolu s $\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}$ a vypočítame optimálne $\hat{\theta}_1^*$.

Sumu kvadrátov odchýlok vypočítame ako $\mathbf{Q}_1 = \mathbf{e}^T \mathbf{e}$, kde $\mathbf{e} = \mathbf{y} - \mathbf{H}_1 \hat{\theta}_1^*$

b) Kvadratická regresia

$$\hat{y}_i = \hat{\theta}_0 + \hat{\theta}_1 u_i + \hat{\theta}_2 u_i^2 = \hat{\theta}_0 + \hat{\theta}_1 f_1(u_i) + \hat{\theta}_2 f_2(u_i) = \begin{bmatrix} \hat{\theta}_0 & \hat{\theta}_1 & \hat{\theta}_2 \end{bmatrix} \begin{bmatrix} 1 & f_1(u_i) & f_2(u_i) \end{bmatrix}^T = \hat{\theta}_2^T \mathbf{f}_2(u_i)$$

pre $i=1, \dots, N$

$$k=2 \quad \mathbf{f}_2(u_i) = \begin{bmatrix} 1 \\ f_1(u_i) \\ f_2(u_i) \end{bmatrix} = \begin{bmatrix} 1 \\ u_i \\ u_i^2 \end{bmatrix}$$

$$\hat{\boldsymbol{\theta}}_2 = \begin{pmatrix} \hat{\theta}_0 \\ \hat{\theta}_1 \\ \hat{\theta}_2 \end{pmatrix}$$

$$\mathbf{H}_2 = \begin{pmatrix} 1 & u_1 & u_1^2 \\ 1 & u_2 & u_2^2 \\ \vdots & \vdots & \vdots \\ 1 & u_N & u_N^2 \end{pmatrix}$$

c) Kubická regresia

$$\hat{y}_i = \hat{\theta}_0 + \hat{\theta}_1 u_i + \hat{\theta}_2 u_i^2 + \hat{\theta}_3 u_i^3 = \hat{\theta}_0 + \hat{\theta}_1 f_1(u_i) + \hat{\theta}_2 f_2(u_i) + \hat{\theta}_3 f_3(u_i) \quad \text{pre } i=1, \dots, N$$

$$k=3 \quad \mathbf{f}_3(u_i) = [1 \ f_1(u_i) \ f_2(u_i) \ f_3(u_i)]^T = [1 \ u_i \ u_i^2 \ u_i^3]^T$$

$$\hat{\boldsymbol{\theta}}_3 = \begin{pmatrix} \hat{\theta}_0 \\ \hat{\theta}_1 \\ \hat{\theta}_2 \\ \hat{\theta}_3 \end{pmatrix}$$

$$\mathbf{H}_3 = \begin{pmatrix} 1 & u_1 & u_1^2 & u_1^3 \\ 1 & u_2 & u_2^2 & u_2^3 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & u_N & u_N^2 & u_N^3 \end{pmatrix}$$

Výsledky:

Lineárna:

$$\hat{\boldsymbol{\theta}}_1 = \begin{bmatrix} 8,8912 \\ -0,5884 \end{bmatrix}$$

$$Q_1 = 4,4252$$

Kvadratická:


$$\hat{\boldsymbol{\theta}}_2 = \begin{bmatrix} 10,4299 \\ -1,1392 \\ 0,0397 \end{bmatrix}$$

$$Q_2 = 3,2498$$

Kubická:

$$\hat{\boldsymbol{\theta}}_3 = \begin{bmatrix} 7,8484 \\ 0,4542 \\ -0,2191 \\ 0,0122 \end{bmatrix}$$

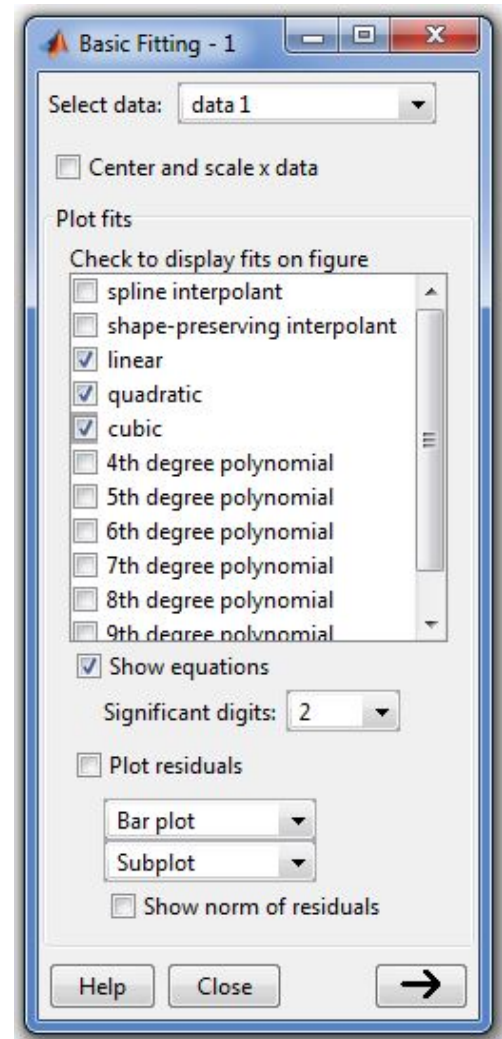
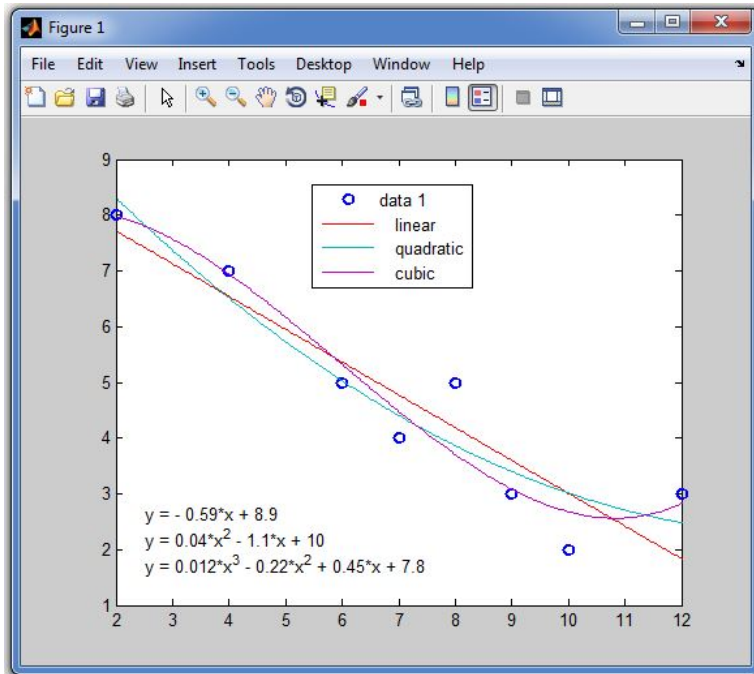
$$Q_3 = 2,5074$$



MATLAB

Basic Fitting GUI

⇒ najskôr je potrebné vykresliť údaje príkazom *plot*
v okne obrázku *Tools – Basic Fitting*



Priklady polyfit a polyval

```
[p1]=polyfit(u,y,1);  
[p2]=polyfit(u,y,2);  
[p3]=polyfit(u,y,3);  
y1=polyval(p1,u);  
y2=polyval(p2,u);  
y3=polyval(p3,u);
```

P = POLYFIT(X,Y,N) finds the coefficients of a polynomial $P(X)$ of degree N that fits the data Y best in a least-squares sense. P is a row vector of length $N+1$ containing the polynomial coefficients in descending powers, $P(1)*X^N + P(2)*X^{(N-1)} + \dots + P(N)*X + P(N+1)$.

Y = POLYVAL(P,X) returns the value of a polynomial P evaluated at X . P is a vector of length $N+1$ whose elements are the coefficients of the polynomial in descending powers.
 $Y = P(1)*X^N + P(2)*X^{(N-1)} + \dots + P(N)*X + P(N+1)$

```
p1 =  
    -0.5884    8.8912  
  
p2 =  
    0.0397   -1.1392   10.4299  
  
p3 =  
    0.0122   -0.2191    0.4542    7.8484
```

Curve Fitting Toolbox

Umožňuje **spracovanie údajov** (vyhladenie, odstránenie niektorých vzoriek), **aproximáciu funkciou** a **porovnanie výsledkov** graficky aj numericky

Možnosti použitia:

- **příkazy** – napr. **fit**
`lin=fit(u,y,'poly1')`
`kvad=fit(u,y,'poly2')`
`y1=lin(u);`
`y2=kvad(u);`

FO = FIT(X, Y, FT) creates a fit object, FO, that encapsulates the result of fitting the model specified by the fittype FT to the data X, Y. FT is a string or a FITTYPE specifying the model to fit.

FITTYPE	DESCRIPTION
'poly1'	Linear polynomial curve
'poly11'	Linear polynomial surface
'poly2'	Quadratic polynomial curve

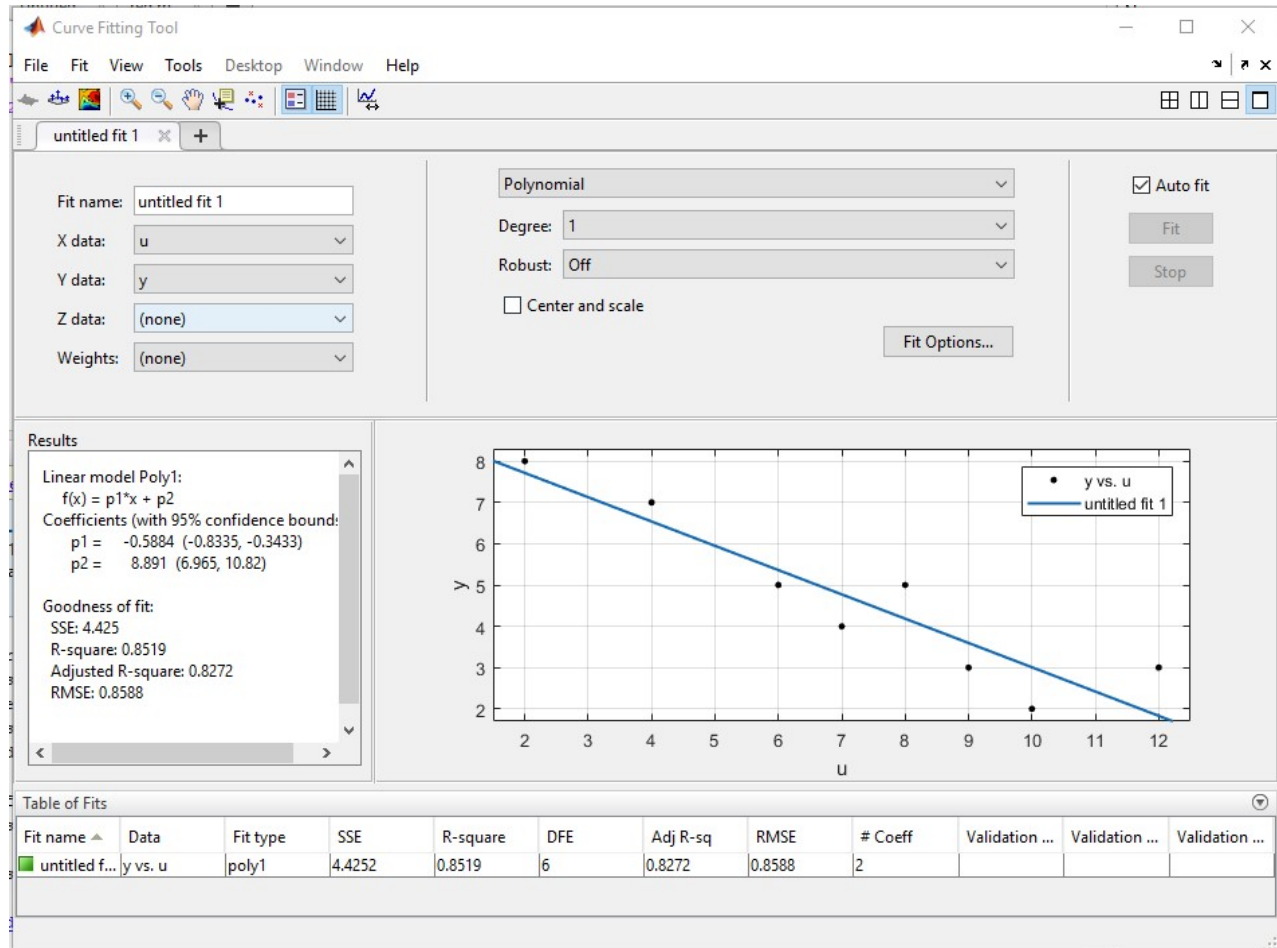
`lin =`

Linear model Poly1:
 $\text{lin}(x) = p1 \cdot x + p2$
Coefficients (with 95% confidence bounds):
 $p1 = -0.5884 \quad (-0.8335, -0.3433)$
 $p2 = 8.891 \quad (6.965, 10.82)$

`kvad =`

Linear model Poly2:
 $\text{kvad}(x) = p1 \cdot x^2 + p2 \cdot x + p3$
Coefficients (with 95% confidence bounds):
 $p1 = 0.03975 \quad (-0.03623, 0.1157)$
 $p2 = -1.139 \quad (-2.219, -0.05897)$
 $p3 = 10.43 \quad (6.928, 13.93)$

- **GUI** (spúšťa sa príkazom *cftool*)



2. Využitie v prípade modelov dynamických systémov – odhad parametrov diskkrétnej prenosovej funkcie metódou najmenších štvorcov

Predpokladajme, že neznámy systém je opísaný diskrétnou prenosovou funkciou 1. rádu

$$F(z) = \frac{b_1 z^{-1}}{1 + a_1 z^{-1}}$$

čo zodpovedá diferenčnej rovnici (v reálnom prostredí treba uvažovať v tejto rovnici náhodnú zložku $v(k)$)

$$y(k) = -a_1 y(k-1) + b_1 u(k-1) + v(k)$$

Hodnoty skutočných (neznámych) parametrov sú $b_1 = 2$, $a_1 = -0.3$

Zvolíme model rovnako v tvare diskkrétnej prenosovej funkcie 1. rádu, ktorá v časovej oblasti zodpovedá diferenčnej rovnici:

$$\hat{y}(k) = -\hat{a}_1 y(k-1) + \hat{b}_1 u(k-1)$$

Táto diferenčná rovnica má tvar lineárnej regresnej rovnice bez absolútneho člena:

$$\hat{y}(k) = -\hat{\theta}_1 y(k-1) + \hat{\theta}_2 u(k-1) = \hat{\boldsymbol{\theta}}^T \mathbf{f}(k) \quad \text{kde } \hat{\theta}_1 = \hat{a}_1 \quad \hat{\theta}_2 = \hat{b}_1$$

Zavedieme označenie: $y_k = y(k)$ $u_k = u(k)$

Potom $\hat{y}_k = \hat{\boldsymbol{\theta}}^T \mathbf{h}_k$

$$\text{kde } \hat{\boldsymbol{\theta}} = \begin{pmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \end{pmatrix} = \begin{pmatrix} \hat{a}_1 \\ \hat{b}_1 \end{pmatrix}$$

$$\mathbf{h}_k^T = \mathbf{f}^T(k) = (-y(k-1), u(k-1))^T$$

Nameriame zašumenú odozvu výstupu systému na jednotkový skok v trvaní 10 s s periódou vzorkovania 1s

$$\{u_0, u_1, u_2, \dots, u_{10}\}^T = \{1, 1, 1, \dots, 1\}^T$$

$$\{y_0, y_1, y_2, \dots, y_{10}\}^T = \{ 0.0732, 1.9734, 2.5706, 2.9929, 2.8777, 2.8799, \\ 3.0932, 2.7358, 2.9614, 2.9823, 2.8206 \}$$

potom môžeme vytvoriť **preurčený systém rovníc**

$$\begin{aligned} e_1 &= y_1 - \hat{y}_1 = y_1 - (-\hat{\theta}_1 y_0 + \hat{\theta}_2 u_0) \\ e_2 &= y_2 - \hat{y}_2 = y_2 - (-\hat{\theta}_1 y_1 + \hat{\theta}_2 u_1) \\ &\vdots \\ e_{10} &= y_{10} - \hat{y}_{10} = y_{10} - (-\hat{\theta}_1 y_9 + \hat{\theta}_2 u_9) \end{aligned}$$

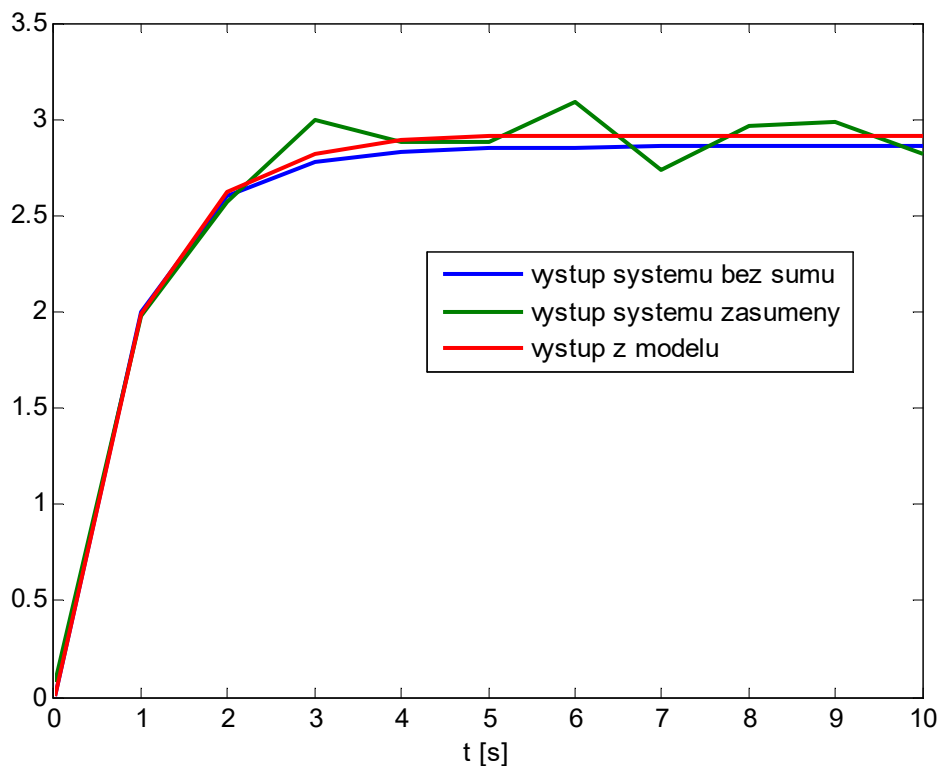
Vytvoríme vektor \mathbf{y} a maticu \mathbf{H}

$$\mathbf{H} = \begin{pmatrix} \mathbf{h}_1^T \\ \mathbf{h}_2^T \\ \vdots \\ \mathbf{h}_{10}^T \end{pmatrix} = \begin{pmatrix} -y_0 & u_0 \\ -y_1 & u_1 \\ \vdots & \vdots \\ -y_9 & u_9 \end{pmatrix} = \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_{10} \end{pmatrix}$$

a vypočítame odhad neznámych parametrov

$$\hat{\boldsymbol{\theta}}^* = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y} = [-0.3199, 1.9846]^T = [a_1, b_1]^T$$

Grafické porovnanie prechodových charakteristík skutočného systému a modelu:



Výsledok výpočtu odhadu parametrov pomocou funkcie arx:

Discrete-time IDPOLY model: $A(q)y(t) = B(q)u(t) + e(t)$

$A(q) = 1 - 0.3199 q^{-1}$

$B(q) = 1.985 q^{-1}$

Estimated using ARX from data set dat

Loss function 0.0146631 and FPE 0.0199952

Sampling interval: 1