

## 6.2 Regresné metódy

⇒ V kapitole 4 boli uvedené rôzne štruktúry lineárnych dynamických systémov. Všeobecne môžeme tieto štruktúry vyjadriť v tvare

$$y_k = G(z^{-1}, \hat{\theta})u_k + H(z^{-1}, \hat{\theta})\xi_k = x_k + v_k$$


kde polynómy

$$H(z^{-1}, \hat{\theta}) = 1 + \sum_{i=1}^{\infty} h_i z^{-i}$$

$$G(z^{-1}, \hat{\theta}) = \sum_{i=1}^{\infty} g_i z^{-i}$$

vo všeobecnosti reprezentujú prenosové funkcie (predelením čitateľa a menovateľa prenosovej funkcie dostaneme IIR – infinite impulse response model).

$\hat{\theta}$  je vektor obsahujúci všetky parametre modelu.



⇒ Výstup  $y_k$  závisí od minulých hodnôt  $y$  a  $u$  a od aktuálnej hodnoty šumu  $v_k$ , ktorý predpokladáme, že je nemerateľný, t.j. použijeme jeho odhad  $\hat{v}_k$  – jednokrokový prediktor

⇒ Odhad  $\hat{v}_k$  na základe minulých hodnôt  $v_{k-i}$ , pričom predpokladáme, že zložky bieleho šumu  $\xi_{k-i}$  nie sú merateľné

$$v_k = H(z^{-1}, \hat{\theta})\xi_k \Rightarrow \xi_k = v_k + (H^{-1}(z^{-1}, \hat{\theta}) - 1)v_k$$

$$v_k = (1 - H^{-1}(z^{-1}, \hat{\theta}))v_k + \xi_k$$

keďže  $\xi_k$  nie je merateľné, odhad (predikcia) aktuálnej hodnoty šumu v čase  $k$  na základe údajov dostupných do času  $(k-1)$  je nasledovný

$$\hat{v}_k = v(k|k-1) = v_k - \xi_k = (1 - H^{-1}(z^{-1}, \hat{\theta}))v_k \quad \text{jednokrokový prediktor}$$

⇒ Odhad výstupnej veličiny  $y_k$

$$\begin{aligned} \hat{y}_k &= y(k|k-1) = G(z^{-1}, \hat{\theta})u_k + \hat{v}_k = G(z^{-1}, \hat{\theta})u_k + (1 - H^{-1}(z^{-1}, \hat{\theta}))v_k = \\ &= G(z^{-1}, \hat{\theta})u_k + (1 - H^{-1}(z^{-1}, \hat{\theta}))(y_k - G(z^{-1}, \hat{\theta})u_k) \end{aligned}$$

$$\hat{y}_k = H^{-1}(z^{-1}, \hat{\theta})G(z^{-1}, \hat{\theta})u_k + (1 - H^{-1}(z^{-1}, \hat{\theta}))y_k \quad \text{jednokrokový prediktor}$$

Dostávame odhad  $\hat{y}_k$ , ktorý vyžaduje iba merateľné minulé vzorky  $y_k$  a  $u_k$ .

⇒ Chyba predikcie má charakter bieleho šumu

$$\begin{aligned} e_k &= y_k - \hat{y}_k = H^{-1}(z^{-1})y_k - H^{-1}(z^{-1})G(z^{-1})u_k = H^{-1}(z^{-1})(y_k - G(z^{-1})u_k) = \\ &= H^{-1}(z^{-1})v_k = \xi_k \end{aligned}$$

Chyba predikcie reprezentuje tú časť výstupu, ktorá nie je predikovateľná z minulých dát.

**Cieľ:** na základe merateľných údajov chceme získať nevychýlený odhad neznámych parametrov  $\hat{\theta}$  modelu systému pre rôzne štruktúry modelov

**Riešenie:** pomocou **regresnej analýzy**, t.j. potrebujeme  $\hat{y}_k$  vyjadriť ako **lineárnu kombináciu neznámych parametrov a merateľných signálov** a budeme **minimalizovať sumu kvadrátov chyby predikcie**.


### 6.2.1 Equation error štruktúry modelov

#### 1. ARX model

$$A(z^{-1}, \hat{\theta}) y_k = B(z^{-1}, \hat{\theta}) u_k + \xi_k$$

$$B(z^{-1}, \hat{\theta}) = b_1 z^{-1} + \dots + b_{n_b} z^{-n_b}$$

$$A(z^{-1}, \hat{\theta}) = 1 + a_1 z^{-1} + \dots + a_{n_a} z^{-n_a}$$



Zodpovedajúca lineárna diferenčná rovnica má tvar

$$y_k = -a_1 y_{k-1} - \dots - a_{n_a} y_{k-n_a} + b_1 u_{k-1} + \dots + b_{n_b} u_{k-n_b} + \xi_k$$

$\xi_k$  **vystupuje v tejto rovnici ako priama chyba**, preto sa táto štruktúra označuje ako **equation error model (chyba rovnice)**.

⇒ Po porovnaní so všeobecnou štruktúrou pre tento prípad platí

$$H(z^{-1}, \hat{\theta}) = \frac{1}{A(z^{-1}, \hat{\theta})}$$

$$G(z^{-1}, \hat{\theta}) = \frac{B(z^{-1}, \hat{\theta})}{A(z^{-1}, \hat{\theta})}$$

Po **dosadení** do všeobecnej rovnice pre **jednokrokovú predikciu**

$$\hat{y}_k = H^{-1}(z^{-1}, \hat{\theta}) G(z^{-1}, \hat{\theta}) u_k + (1 - H^{-1}(z^{-1}, \hat{\theta})) y_k$$

dostaneme

$$\hat{y}_k = B(z^{-1}, \hat{\theta}) u_k + (1 - A(z^{-1}, \hat{\theta})) y_k$$

**Predikcia výstupu má tvar lineárnej regresnej rovnice**

$$\hat{y}_k = b_1 u_{k-1} + b_2 u_{k-2} + \dots + b_{n_b} u_{k-n_b} - a_1 y_{k-1} - a_2 y_{k-2} - \dots - a_{n_a} y_{k-n_a} = \mathbf{h}_k^T \hat{\theta}$$

$$\hat{\theta} = (a_1, a_2, \dots, a_{n_a}, b_1, b_2, \dots, b_{n_b})^T$$

$$\mathbf{h}_k = (-y_{k-1}, -y_{k-2}, \dots, -y_{k-n_a}, u_{k-1}, u_{k-2}, \dots, u_{k-n_b})^T$$

⇒ Na **odhad** vektora parametrov  $\hat{\theta}$  je možné použiť **štandardnú MNŠ**.

**Predpoklad:** máme namerané vstupy a zodpovedajúce výstupy  $u_k$  a  $y_k$  pre  $k=1, \dots, N$ , kde  $N \gg \max(n_a, n_b)$

Pre prípad  $n_a \geq n_b$

$$\mathbf{y} = \begin{pmatrix} y_{n_a} \\ y_{n_a+1} \\ \vdots \\ y_N \end{pmatrix} \quad \mathbf{H} = \begin{pmatrix} -y_{n_a-1} & \dots & -y_0 & u_{n_a-1} & \dots & u_{n_a-n_b} \\ -y_{n_a} & & -y_1 & u_{n_a} & & u_{n_a-n_b+1} \\ \vdots & & \vdots & \vdots & & \vdots \\ -y_{N-1} & \dots & -y_{N-n_a} & u_{N-1} & \dots & u_{N-n_b} \end{pmatrix}$$

**Budeme minimalizovať sumu kvadrátov chyby predikcie**

$$Q(\hat{\theta}) = \sum_{k=1}^N e_k^2 = \sum_{k=1}^N (y_k - \hat{y}_k)^2 = (\mathbf{y} - \mathbf{H}\hat{\theta})^T (\mathbf{y} - \mathbf{H}\hat{\theta}) \Rightarrow \boxed{\hat{\theta}^* = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}}$$

$$e_k = y_k - \hat{y}_k = A(z^{-1}, \hat{\theta}) y_k - B(z^{-1}, \hat{\theta}) u_k = \xi_k$$

**Odchýlka (chyba predikcie) má charakter bieleho šumu  $\Rightarrow$  odhad bude nevychýlený.**

## 2. FIR model

Špeciálny prípad ARX modelu pre  $n_a=0$

$$\boxed{y_k = B(z^{-1}, \hat{\theta}) u_k + \xi_k} \quad B(z^{-1}, \hat{\theta}) = b_1 z^{-1} + \dots + b_{n_b} z^{-n_b}$$

Zodpovedajúca diferenčná rovnica:

$$\boxed{y_k = b_1 u_{k-1} + \dots + b_{n_b} u_{k-n_b} + \xi_k}$$

**Predpoklad:** máme namerané vstupy a zodpovedajúce výstupy  $u_k$  a  $y_k$  pre  $k=1, \dots, N$ , kde  $N \gg n_b$

$$\hat{\theta} = (b_1, b_2, \dots, b_{n_b})^T$$

$$\mathbf{h}_k = (u_{k-1}, u_{k-2}, \dots, u_{k-n_b})^T$$

$$\mathbf{H} = \begin{pmatrix} u_{n_b-1} & u_{n_b-2} & \dots & u_0 \\ u_{n_b} & u_{n_b-1} & & u_1 \\ u_{n_b+1} & u_{n_b} & & \vdots \\ \vdots & \vdots & & \vdots \\ u_{N-1} & u_{N-2} & \dots & u_{N-n_b} \end{pmatrix} \quad \mathbf{y} = \begin{pmatrix} y_{n_b} \\ \vdots \\ y_N \end{pmatrix}$$

Odhad parametrov

$$\boxed{\hat{\theta}^* = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}}$$


## 3. ARMAX model

$$\boxed{A(z^{-1}, \hat{\theta}) y_k = B(z^{-1}, \hat{\theta}) u_k + C(z^{-1}, \hat{\theta}) \xi_k}$$

$$A(z^{-1}, \hat{\theta}) = 1 + a_1 z^{-1} + \dots + a_{n_a} z^{-n_a}$$

$$B(z^{-1}, \hat{\theta}) = b_1 z^{-1} + \dots + b_{n_b} z^{-n_b}$$

$$C(z^{-1}, \hat{\theta}) = 1 + c_1 z^{-1} + \dots + c_{n_c} z^{-n_c}$$



Zodpovedajúca diferenčná rovnica

$$\boxed{y_k = -a_1 y_{k-1} - \dots - a_{n_a} y_{k-n_a} + b_1 u_{k-1} + \dots + b_{n_b} u_{k-n_b} + \xi_k + c_1 \xi_{k-1} + \dots + c_{n_c} \xi_{k-n_c}}$$

Po porovnaní so všeobecnou štruktúrou pre tento prípad platí

$$\boxed{H(z^{-1}, \hat{\theta}) = \frac{C(z^{-1}, \hat{\theta})}{A(z^{-1}, \hat{\theta})}} \quad \boxed{G(z^{-1}, \hat{\theta}) = \frac{B(z^{-1}, \hat{\theta})}{A(z^{-1}, \hat{\theta})}}$$

Po dosadení do rovnice pre **jednokrokovú predikciu** dostaneme

$$\boxed{\hat{y}_k = \frac{B(z^{-1}, \hat{\theta})}{C(z^{-1}, \hat{\theta})} u_k + \left(1 - \frac{A(z^{-1}, \hat{\theta})}{C(z^{-1}, \hat{\theta})}\right) y_k} \Leftrightarrow \hat{y}_k = H^{-1}(z^{-1})G(z^{-1})u_k + (1 - H^{-1}(z^{-1}))y_k$$

Po roznásobením dostaneme

$$C(z^{-1}, \hat{\theta})\hat{y}_k = B(z^{-1}, \hat{\theta})u_k + (C(z^{-1}, \hat{\theta}) - A(z^{-1}, \hat{\theta}))y_k$$

K oboj stranám rovnice pripočítame  $(1 - C(z^{-1}, \hat{\theta}))\hat{y}_k$  a dostaneme

$$\hat{y}_k = B(z^{-1}, \hat{\theta})u_k + (1 - A(z^{-1}, \hat{\theta}))y_k + (C(z^{-1}, \hat{\theta}) - 1)(y_k - \hat{y}_k)$$

kde  $\boxed{e_k(\hat{\theta}) = y_k - \hat{y}_k}$  je chyba predikcie, ktorá je funkciou odhadovaných parametrov  $\hat{\theta}$ .

**Výsledná rovnica má síce tvar lineárnej regresie**

$$\boxed{\hat{y}_k = B(z^{-1}, \hat{\theta})u_k + (1 - A(z^{-1}, \hat{\theta}))y_k + (C(z^{-1}, \hat{\theta}) - 1)e_k(\hat{\theta}) = h_k^T \hat{\theta}}$$

$$\hat{\theta} = (a_1, a_2, \dots, a_{n_a}, b_1, b_2, \dots, b_{n_b}, c_1, c_2, \dots, c_{n_c})^T$$

$$h_k = (-y_{k-1}, -y_{k-2}, \dots, -y_{k-n_a}, u_{k-1}, u_{k-2}, \dots, u_{k-n_b}, e_{k-1}(\hat{\theta}), e_{k-2}(\hat{\theta}), \dots, e_{k-n_c}(\hat{\theta}))^T$$

avšak **vzhľadom k nelineárnemu vplyvu vektora parametrov  $\hat{\theta}$  na vektor  $h^T$  sa nazýva pseudolineárna regresia.**

⇒ **Neexistuje priama metóda výpočtu odhadu parametrov, je potrebná iteratívna metóda ⇒ ROZŠÍRENÁ MNŠ (extended least-squares)**

**Predpoklad:** máme namerané vstupy a zodpovedajúce výstupy  $u_k$  a  $y_k$  pre  $k=1, \dots, N$ , kde  $N \gg \max(n_a, n_b, n_c)$

Pre prípad  $n_a \geq n_b, n_c$

**matica H v i-tej iterácii**

$$H^{(i)} = \begin{pmatrix} -y_{n_a-1} & \dots & -y_0 & u_{n_a-1} & \dots & u_{n_a-n_b} & e_{n_a-1}(\hat{\theta}^{(i-1)}) & \dots & e_{n_a-n_c}(\hat{\theta}^{(i-1)}) \\ -y_{n_a} & & -y_1 & u_{n_a} & & u_{n_a-n_b+1} & e_{n_a}(\hat{\theta}^{(i-1)}) & & e_{n_a-n_c+1}(\hat{\theta}^{(i-1)}) \\ -y_{n_a+1} & & & & & & & & \\ \vdots & & \vdots & \vdots & & \vdots & \vdots & & \vdots \\ -y_{N-1} & \dots & -y_{N-n_a} & u_{N-1} & \dots & u_{N-n_b} & e_{N-1}(\hat{\theta}^{(i-1)}) & \dots & e_{N-n_c}(\hat{\theta}^{(i-1)}) \end{pmatrix} \quad y = \begin{pmatrix} y_{n_a} \\ y_{n_a+1} \\ \vdots \\ y_N \end{pmatrix}$$

☑ **Postup:**

1. **Štart pomocou metódy najmenších štvorcov (nultá iterácia,  $i=0$ )**

$$\mathbf{y} = \begin{pmatrix} y_{n_a} \\ y_{n_a+1} \\ \vdots \\ y_N \end{pmatrix} \quad \mathbf{H}^{(0)} = \begin{pmatrix} -y_{n_a-1} & \dots & -y_0 & u_{n_a-1} & \dots & u_{n_a-n_b} \\ -y_{n_a} & & -y_1 & u_{n_a} & & u_{n_a-n_b+1} \\ \vdots & & \vdots & \vdots & & \vdots \\ -y_{N-1} & \dots & -y_{N-n_a} & u_{N-1} & \dots & u_{N-n_b} \end{pmatrix}$$

$$\hat{\boldsymbol{\theta}}^{(0)} = (\mathbf{H}^{(0)\top} \mathbf{H}^{(0)})^{-1} \mathbf{H}^{(0)\top} \mathbf{y} \quad \text{kde} \quad \hat{\boldsymbol{\theta}}^{(0)} = (a_1, a_2, \dots, a_{n_a}, b_1, b_2, \dots, b_{n_b})^\top$$

2. Vypočítame **chyby predikcie** pre  $i=0$

$$\mathbf{e}_k(\hat{\boldsymbol{\theta}}^{(0)}) = y_k - \hat{y}_k(\hat{\boldsymbol{\theta}}^{(0)})$$

$$\hat{y}_k(\hat{\boldsymbol{\theta}}^{(0)}) = B(z^{-1}, \hat{\boldsymbol{\theta}}^{(0)}) u_k + (1 - A(z^{-1}, \hat{\boldsymbol{\theta}}^{(0)})) y_k =$$

$$= b_1 u_{k-1} + b_2 u_{k-2} + \dots + b_{n_b} u_{k-n_b} - a_1 y_{k-1} - a_2 y_{k-2} - \dots - a_{n_a} y_{k-n_a}$$

3. Pre  $i=1, \dots, M$  kde  $M$  je počet iterácií

Vytvoríme **maticu  $\mathbf{H}^{(i)}$**

$$\mathbf{H}^{(i)} = \begin{pmatrix} -y_{n_a-1} & \dots & -y_0 & u_{n_a-1} & \dots & u_{n_a-n_b} & e_{n_a-1}(\hat{\boldsymbol{\theta}}^{(i-1)}) & \dots & e_{n_a-n_c}(\hat{\boldsymbol{\theta}}^{(i-1)}) \\ -y_{n_a} & & -y_1 & u_{n_a} & & u_{n_a-n_b+1} & e_{n_a}(\hat{\boldsymbol{\theta}}^{(i-1)}) & & e_{n_a-n_c+1}(\hat{\boldsymbol{\theta}}^{(i-1)}) \\ -y_{n_a+1} & & & & & & & & \\ \vdots & & \vdots & \vdots & & \vdots & \vdots & & \vdots \\ -y_{N-1} & \dots & -y_{N-n_a} & u_{N-1} & \dots & u_{N-n_b} & e_{N-1}(\hat{\boldsymbol{\theta}}^{(i-1)}) & \dots & e_{N-n_c}(\hat{\boldsymbol{\theta}}^{(i-1)}) \end{pmatrix}$$

Vypočítame **odhad vektora parametrov**

$$\hat{\boldsymbol{\theta}}^{(i)} = (\mathbf{H}^{(i)\top} \mathbf{H}^{(i)})^{-1} \mathbf{H}^{(i)\top} \mathbf{y} \quad \text{kde} \quad \hat{\boldsymbol{\theta}}^{(i)} = (a_1, a_2, \dots, a_{n_a}, b_1, b_2, \dots, b_{n_b}, c_1, c_2, \dots, c_{n_c})^\top$$

Vypočítame **chyby predikcie**

$$\hat{y}_k^{(i)} = B(z^{-1}, \hat{\boldsymbol{\theta}}^{(i)}) u_k + (1 - A(z^{-1}, \hat{\boldsymbol{\theta}}^{(i)})) y_k + (C(z^{-1}, \hat{\boldsymbol{\theta}}^{(i)}) - 1) e_k(\hat{\boldsymbol{\theta}}^{(i)})$$

$$e_k(\hat{\boldsymbol{\theta}}^{(i)}) = y_k - \hat{y}_k(\hat{\boldsymbol{\theta}}^{(i)})$$

Prejdeme na **d'alšiu iteráciu  $i=i+1$** .

**Poznámka:**

**Počet iterácií  $M$**  je buď **vopred zvolený** alebo je **daný konvergenciou** odhadovaných **parametrov**.

## 6.2.2 Output error štruktúry modelov


### 1. OEM (output error model)

$$y_k = \frac{B(z^{-1}, \hat{\theta})}{F(z^{-1}, \hat{\theta})} u_k + \xi_k = x_k + \xi_k$$

$$B(z^{-1}, \hat{\theta}) = b_1 z^{-1} + \dots + b_{nb} z^{-nb}$$

$$F(z^{-1}) = 1 + f_1 z^{-1} + \dots + f_{nf} z^{-nf}$$

$$x_k(\hat{\theta}) = \frac{B(z^{-1}, \hat{\theta})}{F(z^{-1}, \hat{\theta})} u_k \quad x_k - \text{neskreslený výstup}$$



**Neskreslený výstup nie je merateľný, preto je funkciou odhadovaných parametrov**, potom zodpovedajúca diferenčná rovnica má tvar

$$x_k(\hat{\theta}) = -f_1 x_{k-1}(\hat{\theta}) - \dots - f_{nf} x_{k-nf}(\hat{\theta}) + b_1 u_{k-1} + \dots + b_{nb} u_{k-nb}$$

Pre tento model platí

$$G(z^{-1}, \hat{\theta}) = \frac{B(z^{-1}, \hat{\theta})}{F(z^{-1}, \hat{\theta})}$$

$$H(z^{-1}, \hat{\theta}) = 1$$

Po dosadení do vzťahu pre **jednokrokovú predikciu výstupu**

$$\hat{y}_k = \frac{B(z^{-1}, \hat{\theta})}{F(z^{-1}, \hat{\theta})} u_k = x_k(\hat{\theta}) \quad \Leftrightarrow \quad \hat{y}_k = H^{-1}(z^{-1}) G(z^{-1}) u_k + (1 - H^{-1}(z^{-1})) y_k$$

$$\hat{y}_k = x_k(\hat{\theta}) = (1 - F(z^{-1}, \hat{\theta})) x_k + B(z^{-1}, \hat{\theta}) u_k = z_k^T \hat{\theta}$$

$$\hat{\theta} = (f_1, f_2, \dots, f_{nf}, b_1, b_2, \dots, b_{nb})^T$$

$$z_k = (-x_{k-1}(\hat{\theta}), \dots, -x_{k-nf}(\hat{\theta}), u_{k-1}, \dots, u_{k-nb})^T$$

**Keďže vektor  $z_k$  závisí od odhadovaných parametrov, opäť sa jedná o pseudolineárnu regresiu.**

**Vyžaduje to iteratívnu metódu  $\Rightarrow$  METÓDA INŠTRUMENTÁLNYCH PREMENNÝCH (instrumental variable (IV) method)**

Nemerateľný **neskreslený výstup** vo vektore **z** môže byť **nahradený predikovaným výstupom**.

Zavedieme tzv. **inštrumentálne premenné**

$$x_{k-j}(\hat{\theta}) = \hat{y}_{k-j}$$

pre  $j=1, 2, \dots, n_f$

⇒ Ak by sme ako regresnú rovnicu nepoužili rovnicu pre jednokrokovú predikciu výstupu, ale priamo diferenčnú rovnicu pre výstup

$$y_k = \frac{B(z^{-1}, \hat{\theta})}{F(z^{-1}, \hat{\theta})} u_k + \xi_k \quad \Rightarrow \quad F(z^{-1}, \hat{\theta}) y_k = B(z^{-1}, \hat{\theta}) u_k + F(z^{-1}, \hat{\theta}) \xi_k = B(z^{-1}, \hat{\theta}) u_k + v_k$$

kde  $v_k = F(z^{-1}, \hat{\theta}) \xi_k$  je farebný šum – MA proces.

Dostaneme diferenčnú rovnicu

$$y_k = -f_1 y_{k-1} - \dots - f_{n_f} y_{k-n_f} + b_1 u_{k-1} + \dots + b_{n_b} u_{k-n_b} + v_k = \mathbf{h}^T \hat{\theta} + v_k$$

Odhad parametrov vypočítaný ako  $\hat{\theta}^* = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$

$$\text{kde} \quad \mathbf{H} = \begin{pmatrix} -y_{n_f-1} & \dots & -y_0 & u_{n_f-1} & \dots & u_{n_f-n_b} \\ -y_{n_f} & & -y_1 & u_{n_f} & & u_{n_f-n_b+1} \\ \vdots & & \vdots & \vdots & & \vdots \\ -y_{N-1} & \dots & -y_{N-n_f} & u_{N-1} & \dots & u_{N-n_b} \end{pmatrix} \quad \mathbf{y} = \begin{pmatrix} y_{n_f} \\ \vdots \\ y_N \end{pmatrix}$$

však bude vychýlený.

$$\hat{\theta}^* = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T (\mathbf{H} \theta + \mathbf{v}) = \theta + (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{v}$$

$$E\{\hat{\theta}^*\} = \theta + E\{(\mathbf{H}^T \mathbf{H})^{-1}\} E\{\mathbf{H}^T \mathbf{v}\}$$

Podmienka nevychýlenosti odhadu  $E\{\hat{\theta}^*\} = \theta \Rightarrow E\{(\mathbf{H}^T \mathbf{H})^{-1}\} E\{\mathbf{H}^T \mathbf{v}\} = 0$

Keďže  $E\{(\mathbf{H}^T \mathbf{H})^{-1}\} > 0$ , aby sme dostali nevychýlený odhad malo by platiť  $E\{\mathbf{H}^T \mathbf{v}\} = 0$ ,

čo znamená, že **signály, ktoré obsahuje matica  $\mathbf{H}$  ( $y_k, u_k$ ) by nemali byť korelované so signálmi, ktoré obsahuje vektor  $\mathbf{v}$  ( $v_k$ ).**

Signál **výstupu je korelovaný s farebným šumom  $\mathbf{v}$** , preto neplatí  $E\{\mathbf{H}^T \mathbf{v}\} = 0$  a odhad parametrov je vychýlený.

Namiesto matice  $\mathbf{H}$  použijeme takú maticu  $\mathbf{Z}$ , ktorej prvky nie sú korelované s farebným šumom  $\mathbf{v}$ , t.j. namiesto výstupu  $y_k$  použijeme neskreslený výstup  $x_k$  – inštrumentálne premenné.

⇒ **METÓDA INŠTRUMENTÁLNYCH PREMENNÝCH**

**Predpoklad:** máme namerané vstupy a zodpovedajúce výstupy  $u_k$  a  $y_k$  pre  $k=1, \dots, N$ , kde  $N \gg \max(n_f, n_b)$

Pre prípad  $n_f \geq n_b$

### Matica inštrumentálnych premenných v i-tej iterácii

$$\mathbf{Z}^{(i)} = \begin{pmatrix} -x_{n_f-1}(\hat{\theta}^{(i-1)}) & \dots & -x_0(\hat{\theta}^{(i-1)}) & u_{n_f-1} & \dots & u_{n_f-n_b} \\ -x_{n_f}(\hat{\theta}^{(i-1)}) & & -x_1(\hat{\theta}^{(i-1)}) & u_{n_f} & & u_{n_f-n_b+1} \\ \vdots & & \vdots & \vdots & & \vdots \\ -x_{N-1}(\hat{\theta}^{(i-1)}) & \dots & -x_{N-n_f}(\hat{\theta}^{(i-1)}) & u_{N-1} & \dots & u_{N-n_b} \end{pmatrix}$$

$$\mathbf{y} = \begin{pmatrix} y_{n_f} \\ \vdots \\ y_N \end{pmatrix}$$

$$\mathbf{H} = \begin{pmatrix} -y_{n_f-1} & \dots & -y_0 & u_{n_f-1} & \dots & u_{n_f-n_b} \\ -y_{n_f} & & -y_1 & u_{n_f} & & u_{n_f-n_b+1} \\ \vdots & & \vdots & \vdots & & \vdots \\ -y_{N-1} & \dots & -y_{N-n_f} & u_{N-1} & \dots & u_{N-n_b} \end{pmatrix}$$

Odhad parametrov v i-tom kroku  $\hat{\theta}^{(i)} = (\mathbf{Z}^{(i)\top} \mathbf{H})^{-1} \mathbf{Z}^{(i)\top} \mathbf{y}$

#### ☑ Postup:

1. **Štart** pomocou **metódy najmenších štvorcov** (nultá iterácia, **i=0**), t.j.  $\mathbf{Z}^{(0)}=\mathbf{H}$ .  
Vypočítame **vychýlený odhad parametrov**

$$\hat{\theta}^{(0)} = (\mathbf{H}^\top \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{y} \quad \text{kde} \quad \hat{\theta}^{(0)} = (f_1, f_2, \dots, f_{n_f}, b_1, b_2, \dots, b_{n_b})^\top$$

2. Vypočítame **inštrumentálne premenné** pre  $i=0$  a  $k=0, \dots, N-1$

$$x_k(\hat{\theta}^{(0)}) = -f_1 x_{k-1}(\hat{\theta}^{(0)}) - \dots - f_{n_f} x_{k-n_f}(\hat{\theta}^{(0)}) + b_1 u_{k-1} + \dots + b_{n_b} u_{k-n_b}$$

3. Pre **i=1, ..., M** kde **M** je počet iterácií

Vytvoríme **matice**  $\mathbf{Z}^{(i)}$  a  $\mathbf{H}$  a vypočítame **odhad parametrov**

$$\hat{\theta}^{(i)} = (\mathbf{Z}^{(i)\top} \mathbf{H})^{-1} \mathbf{Z}^{(i)\top} \mathbf{y} \quad \text{kde} \quad \hat{\theta}^{(i)} = (f_1, f_2, \dots, f_{n_f}, b_1, b_2, \dots, b_{n_b})^\top$$

Vypočítame **inštrumentálne premenné**  $x_0(\hat{\theta}^{(i)}), x_1(\hat{\theta}^{(i)}), \dots, x_{N-1}(\hat{\theta}^{(i)})$

$$x_k(\hat{\theta}^{(i)}) = -f_1 x_{k-1}(\hat{\theta}^{(i)}) - \dots - f_{n_f} x_{k-n_f}(\hat{\theta}^{(i)}) + b_1 u_{k-1} + \dots + b_{n_b} u_{k-n_b}$$

Prejdeme na **d'alšiu iteráciu i=i+1**.